UNIVERSIDAD NACIONAL DE INGENIERÍA

UNIDAD DE POSGRADO – FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

INFORME PARCIAL

PROYECTO DE INVESTIGACIÓN II

PLAN DE TESIS Y PROTOCOLO DE INVESTIGACIÓN

Título de tesis: Sistema de análisis satelital de inundaciones basado en modelos de segmentación profunda para el mapeo de áreas inundadas en el Perú

Programa: Maestría en Ciencias con mención en Inteligencia Artificial

Estudiantes: Gerson Andre Garrido Mansilla y Renzo Elvis Cerron Tome

Asesor: por asignar

Docentes del curso: Glen Rodríguez R. y Wester Zela

Lugar y fecha: Lima, noviembre de 2026

Índice

PARTE I. PLAN DE TESIS 3

Datos generales 3

I. PLANTEAMIENTO DEL PROBLEMA 3

1.1. Diagnóstico 3

1.2. Justificación y alcances 7

II. OBJETIVOS 8

2.1. Objetivo general 8

2.2. Objetivos específicos 8

III. MARCO TEÓRICO 9

3.1. Bases teóricas 9

3.2. Definición de términos 11

IV. METODOLOGÍA 12

4.1. Tipo de investigación 12

4.2. Nivel de investigación 12

4.3. Métodos de trabajo 12

4.4. Población y muestra 12

4.5. Tipo de diseño 13

4.6. Técnicas e instrumentos de recolección de datos 13

4.7. Técnicas e instrumentos de análisis y procesamiento de datos 13

4.8. Etapas de intervención del estudio 14

V. ADMINISTRACIÓN DEL PLAN DE TESIS 14

5.1. Cronograma 14

5.2. Presupuesto 15

5.3. Financiamiento 16

PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL 17

6. Datos y material de estudio 17

6.1. Origen, condiciones de uso y trazabilidad 17

6.2. Estructura, diccionario de datos y análisis exploratorio . . . 18
6.3. Ética, privacidad y seguridad . . . 19
6.4. Preprocesamiento y control de fuga de información . . . 20
7. Protocolo experimental . . . 20
7.1. Preguntas de evaluación y criterios de éxito . . . 21
7.2. Diseño de particiones y validación . . . 22
7.3. Métricas y análisis estadístico . . . 23
7.4. *Baseline* y variantes . . . 23
7.5. Ingeniería de atributos o componentes . . . 25
7.6. Optimización y presupuesto de búsqueda . . . 26
7.7. Reproducibilidad y registro de experimentos . . . 27
8. Resultados parciales y evidencia . . . 27
8.1. Estado de implementación del *pipeline* . . . 28
8.2. Comparación cuantitativa del *baseline* y variantes . . . 29
8.3. Ablaciones y análisis de sensibilidad . . . 31
8.4. Sobreajuste, errores y robustez . . . 33
8.5. Interpretación y amenazas a la validez . . . 35
9. Conclusiones del avance y próximos pasos . . . 37
9.1. Conclusiones sustentadas por evidencia . . . 37
9.2. Riesgos y plan de mitigación . . . 37
9.3. Trabajo futuro para el siguiente *sprint* . . . 39
REFERENCIAS . . . 40
ANEXOS . . . 44
Anexo A. Matriz de consistencia . . . 44
Anexo B. Cronograma detallado . . . 45
Anexo C. Diccionario de datos . . . 46
Anexo D. Registro de corridas . . . 47
Anexo E. Evidencia de ejecución . . . 48

PARTE I. PLAN DE TESIS

Datos generales

La Tabla 1 reúne los datos generales del plan de tesis.

Tabla 1
Datos generales del plan de tesis

Campo	Información
Título del plan	Sistema de análisis satelital de inundaciones basado en modelos de segmentación profunda para el mapeo de áreas inundadas en el Perú
Autores	Gerson Andre Garrido Mansilla y Renzo Elvis Cerron Tome
Asesor	Por asignar. Las decisiones de la investigación las toman los autores, con la orientación general de los docentes del curso.
Unidad de posgrado y programa	Unidad de Posgrado de la Facultad de Ingeniería Industrial y de Sistemas, Universidad Nacional de Ingeniería. Maestría en Ciencias con mención en Inteligencia Artificial.
Lugar de desarrollo	Lima, Perú. El trabajo es computacional; la zona de estudio comprende los departamentos de Lambayeque y Piura.
Duración estimada	Inicio: septiembre de 2026. Borrador integral de la tesis: enero de 2027 (semana 16 del curso). La fecha de sustentación está por definir.

Nota. Elaboración propia.

CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA

1.1 Diagnóstico

En la costa norte del Perú, las lluvias intensas asociadas al calentamiento anómalo del mar producen inundaciones recurrentes de gran magnitud. Para el Niño Costero de 2017, el Instituto Nacional de Defensa Civil (INDECI) informó, con datos procesados al 4 de julio de ese año, un total nacional de 285 453 damnificados, 1 454 051 afectados y 138 fallecidos (Instituto Nacional de Defensa Civil, 2017, p. 13), y las pérdidas se estimaron en US$ 3.1 mil millones (French et al., 2020, Tabla 1). En marzo de 2023, cuando el Índice Costero El Niño correspondió a la categoría cálida moderada (Comisión Multisectorial encargada del Estudio Nacional del Fenómeno “El Niño” (ENFEN), 2023, Tabla 2, p. 10 del PDF), el INDECI atribuyó al episodio asociado al ciclón Yaku, entre el 4 y el 20 de marzo, 107 780 damnificados y 44 fallecidos en ocho departamentos, entre ellos Lambayeque y Piura (Instituto Nacional de Defensa Civil, 2024, Tabla 6, p. 86).

Durante esas emergencias, la extensión del agua se cartografió de forma experta y después del evento. Para el ciclón Yaku, el Centro de Satélites de las Naciones Unidas (UNOSAT) delimitó sobre imágenes Sentinel-2 una inundación de 985.9 km² al 22 de marzo de 2023, y advirtió que era un producto preliminar, no validado en campo (United Nations Satellite Centre (UNOSAT),

2023b). Para el Niño Costero de 2017, el servicio Copernicus de gestión de emergencias (EMS) elaboró delimitaciones sobre imágenes de radar (Copernicus Emergency Management Service, 2017).

El diagnóstico distingue tres niveles.

- **Síntomas.** Los mapas de la extensión del agua dependen del trabajo de especialistas y se publican después del evento, como productos preliminares. Los modelos automáticos disponibles se entrenaron con datos de otras regiones: aplicados a la costa peruana sin ningún ajuste, marcan como agua parte del desierto, y en la partición de prueba peruana de 2023 obtienen un IoU de agua de entre 0.576 y 0.740, frente a 0.82–0.83 en su conjunto de origen (Sección 8.2).
- **Causas.** En las fuentes consultadas no se identificó un conjunto público de imágenes ópticas peruanas con etiquetas de inundación. El suelo seco de la costa árida es mucho más brillante que el de los conjuntos internacionales, lo que produce un cambio de dominio. Además, las probabilidades que entregan los modelos no siempre corresponden a su frecuencia de acierto.
- **Consecuencias.** Un mapa automático que sobreestima el agua, sin una medida confiable de su incertidumbre, tiene poco valor como insumo para estimar la extensión de una inundación poco después del paso del satélite.

1.1.1 Identificación y descripción del problema de estudio

El problema es cómo integrar y evaluar modelos de segmentación profunda en un sistema que mapee el agua con imágenes Sentinel-2 en el Perú, dado que esos modelos pueden perder desempeño y calibración cuando se aplican fuera de los datos con que se entrenaron. La delimitación es la siguiente.

- **Objeto de estudio.** Un sistema de análisis satelital basado en tres modelos: TerraMind v1-B y Prithvi-EO-2.0 300M, que son modelos fundacionales geoespaciales, y una U-Net como referencia convolucional.
- **Ubicación y ámbito.** Costa norte del Perú: Lambayeque y Piura en 2023, y bajo Piura y Sechura en 2017. El dominio de origen es el conjunto global Sen1Floods11 (Bonafilia et al., 2020).
- **Período.** Imágenes Sentinel-2 del 22 de marzo y del 1 de abril de 2023 (ciclón Yaku) y del 7 de abril de 2017 (Niño Costero).
- **Variable dependiente.** La calidad del mapeo de inundaciones, que incluye la exactitud de la segmentación, su calibración y el desempeño del sistema.

1.1.2 Antecedentes bibliográficos

Los antecedentes se resumen en orden cronológico; la Tabla 2 recoge los más cercanos. La búsqueda no es una revisión sistemática.

Modelos y conjuntos de referencia. Sen1Floods11 reúne 446 recortes de Sentinel-1 y Sentinel-2 etiquetados a mano en 11 eventos de inundación (Bonafilia et al., 2020) y es el conjunto con el que se comparan los modelos. En él, W. Li et al. (2023) obtuvieron un IoU de agua de 84.03 % con una U-Net y de 81.98 % con Prithvi-100M; en Bolivia, región excluida del entrenamiento, el orden se invirtió (76.62 frente a 70.57 %) (W. Li et al., 2023, Tablas 2 y 3). Los modelos fundacionales más recientes reportan valores similares en la distribución de entrenamiento: 82.2 % para Prithvi-EO-2.0 300M (Szwarcman et al., 2024, Tabla IV, p. 12 del PDF) y 82.26 % para TerraMind v1-B (Jakubik et al., 2025, Tabla 8, p. 7390). En el banco de pruebas PANGAEA, con los codificadores congelados, una U-Net obtuvo el mayor mIoU, 91.42 % (Marsocci et al., 2026, Tabla 5, p. 13 del PDF).

Generalización y adaptación. Kolluru et al. (2026) aplicaron sin adaptación el modelo público de Prithvi-EO-2.0 a 19 eventos no vistos y obtuvieron, frente al producto automático Copernicus GFM, un IoU medio por evento de 0.46, con precisión de 0.49 y *recall* de 0.90 (Kolluru et al., 2026, p. 7); advierten que GFM excluye el agua permanente, de modo que parte del desacuerdo viene de la definición de agua. En adaptación de dominio, el conjunto LoveDA mostró que el autoentrenamiento lleva la clase agua de 49.42 a 64.49, cerca de la cota superior de 65.89 (Wang et al., 2021, Tabla 6, p. 8 del PDF); su protocolo de tres niveles (sin adaptar, adaptado y cota superior) es el que sigue esta investigación. Chen et al. (2026) elevaron una U-Net de 0.636 a 0.803 de IoU con autoentrenamiento en inundaciones costeras, pero con radar y sin adaptar el modelo fundacional (Chen et al., 2026, Tabla 4).

Calibración. Las redes neuronales modernas tienden a ser sobreconfiadas (Guo et al., 2017), y la calidad de la incertidumbre se degrada bajo cambio de dominio (Ovadia et al., 2019). Banerjee y Daou (2026) midieron el error de calibración esperado (ECE) en Sen1Floods11 con radar y tres clases: 0.0675 para una U-Net y 0.0694 para SegFormer-b2 (Banerjee y Daou, 2026, Tabla 5, p. 12 del PDF).

Estudios en el Perú. Shen et al. (2022) entrenaron modelos UNet++ con Sen1Floods11 y los aplicaron a la inundación del río Piura de 2017, con un IoU de extracción de agua de 0.69 (Shen et al., 2022, Tabla 3, p. 137). Breña-Aliaga y Cruz-Machacuay (2026) estimaron la dinámica de las inundaciones en la cuenca del río Tumbes con bosque aleatorio y radar, con un IoU de 69.02 % (Breña-Aliaga y Cruz-Machacuay, 2026, Tabla 2, p. 221).

Tabla 2
Antecedentes más cercanos a la investigación

Estudio	Método	Datos y región	Resultado	Limitación frente a este estudio
W. Li et al. (2023)	Prithvi-100M frente a U-Net	Sen1Floods11; Bolivia excluida	IoU de agua: U-Net 84.03, Prithvi 81.98; Bolivia: 70.57 y 76.62	Sin el Perú, sin adaptación ni calibración
Shen et al. (2022)	UNet++ entrenada en Sen1Floods11	Sentinel-1 y 2; Piura 2017	IoU de agua 0.69	Sin modelos fundacionales ni calibración
Kolluru et al. (2026)	Prithvi-EO-2.0 sin adaptación	HLS (30 m), 19 eventos	IoU medio 0.46; precisión 0.49 (frente a GFM)	Sin adaptación; referencia automática
Chen et al. (2026)	Autoentrenamiento en la prueba	Sentinel-1	IoU de 0.636 a 0.803	Radar; modelo fundacional sin adaptar
Breña-Aliaga y Cruz-Machacuay (2026)	Bosque aleatorio, SDWI y HAND	Sentinel-1; Tumbes 2023–2025	IoU 69.02 %	Radar y aprendizaje clásico
Banerjee y Daou (2026)	U-Net y SegFormer con ECE	Sen1Floods11 (radar)	ECE 0.0675 y 0.0694	Radar; sin cambio de dominio

Nota. Elaboración propia a partir de las tablas citadas en el texto. Cada valor se reproduce en la escala de su fuente (porcentaje o proporción).

Brecha. En las fuentes consultadas no se identificaron estudios que evalúen y adapten modelos fundacionales geoespaciales con imágenes Sentinel-2 de la costa árida peruana sin datos etiquetados locales para el entrenamiento, ni que midan la calibración de modelos ópticos de inundación bajo cambio de dominio. Como la búsqueda no es sistemática, no se afirma que tales estudios no existan.

1.1.3 Formulación del problema

Problema general. ¿De qué manera se puede desarrollar un sistema de análisis satelital de inundaciones para el Perú, basado en modelos de segmentación profunda, que genere mapas de la extensión del agua y de su incertidumbre a partir de imágenes Sentinel-2, aun cuando no se dispone de datos etiquetados del Perú para entrenar los modelos?

Problemas específicos.

1. ¿Qué modelo de segmentación (TerraMind, Prithvi o U-Net) y qué esquema de entrenamiento ofrecen el mejor desempeño en Sen1Floods11 y en el Perú?

2. ¿En qué medida la adaptación de dominio sin datos etiquetados del Perú reduce la pérdida de desempeño de los modelos, y está calibrada la incertidumbre que mostrará el sistema?
3. ¿En qué medida el sistema implementado cumple los requisitos funcionales y el tiempo de procesamiento necesarios para usarlo después de un evento de inundación?

1.2 Justificación y alcances

La investigación se justifica en los planos teórico, práctico y metodológico, y sus alcances se delimitan por tema, espacio y tiempo.

1.2.1 Justificación

Teórica. Se compara cuánto cambia el IoU de agua de los modelos fundacionales y de la U-Net al pasar de Sen1Floods11 a la costa desértica peruana. Esa comparación permite examinar si el preentrenamiento geoespacial se traduce en una menor pérdida de desempeño en una región que los modelos no vieron, y si sus probabilidades siguen correspondiendo a su frecuencia de acierto.

Práctica. Ante una inundación nueva hay imágenes satelitales, pero no etiquetas locales para ajustar un modelo. Un sistema que obtenga la imagen Sentinel-2, aplique un modelo y muestre el mapa del agua junto con su incertidumbre permitiría estimar la extensión de la inundación poco después del paso del satélite. La utilidad para las entidades de gestión del riesgo deberá examinarse después con usuarios; esta investigación no la evalúa.

Metodológica. Se construye un conjunto de datos peruano a partir de mapas expertos, sin etiquetado manual, con particiones espaciales que evalúan en zonas distintas de las de entrenamiento. Cada configuración se ejecuta con tres semillas y se congela antes de una única evaluación en prueba, y las diferencias entre métodos se acompañan de intervalos de confianza por remuestreo. El procedimiento queda documentado y puede repetirse con otros modelos.

1.2.2 Alcances

Lo que cubre el estudio. La detección de la extensión del agua (segmentación binaria: agua y no agua) en imágenes ópticas Sentinel-2 de nivel 1C, con tres modelos, tres esquemas de entrenamiento y métodos de adaptación de dominio no supervisada, y su integración en una aplicación web. La evaluación del sistema es técnica: requisitos funcionales y tiempo de procesamiento.

Lo que no cubre. El pronóstico de inundaciones, las imágenes de radar, los mapas de susceptibilidad o de riesgo y las pruebas con usuarios finales. Los modelos detectan el agua visible en la fecha de la imagen, incluida el agua permanente; por sí solos no distinguen el agua causada por la inundación.

Supuestos y restricciones.

- Las etiquetas peruanas provienen de productos expertos preliminares (UNOSAT) o delimitados sobre radar días antes de la imagen óptica (Copernicus EMS). Contienen errores que afectan a las métricas.
- Las imágenes ópticas no observan el suelo bajo las nubes; esos píxeles se excluyen.
- Se usan tres semillas por configuración, por el costo de cómputo.
- El sistema es un prototipo de investigación: no se evalúa su operación continua.

CAPÍTULO II. OBJETIVOS

Los objetivos responden uno a uno a los problemas formulados. La Tabla 3 indica con qué actividades y con qué evidencia se verificará cada objetivo específico.

2.1 Objetivo general

Desarrollar un sistema de análisis satelital de inundaciones para el Perú, basado en modelos de segmentación profunda, que genere mapas de la extensión del agua y de su incertidumbre a partir de imágenes Sentinel-2.

2.2 Objetivos específicos

1. Comparar el IoU de agua de TerraMind v1-B, Prithvi-EO-2.0 300M y U-Net en Sen1Floods11 y en los eventos peruanos de 2023 y 2017, con tres esquemas de entrenamiento, para seleccionar el modelo del sistema.
2. Determinar en qué medida la adaptación de dominio no supervisada y la calibración de la incertidumbre mejoran la confiabilidad de los mapas en el Perú, e identificar las condiciones en las que se concentran los errores.
3. Implementar el sistema como una aplicación web y evaluar si cumple los requisitos funcionales y el tiempo de procesamiento por escena Sentinel-2.

Tabla 3
Actividades y evidencia de cada objetivo específico

Objetivo	Actividades	Evidencia de cumplimiento	Estado al corte
OE1	Entrenar los tres modelos con tres esquemas y tres semillas; evaluar una sola vez en las particiones de prueba	Tablas de IoU con diferencias pareadas e intervalos de confianza al 95 %	Cumplido
OE2	Aplicar los métodos de adaptación; ajustar la temperatura y formar ensambles; analizar los errores por condición	Diferencia de IoU entre el modelo adaptado y el modelo sin adaptar; ECE; AUROC; proporción de errores por condición	Cumplido, salvo un análisis menor de 2017
OE3	Implementar la aplicación; probar los requisitos RF1 a RF7; medir el tiempo en seis teselas con tres repeticiones	Lista de verificación de requisitos; mediana del tiempo por tesela	En curso: sistema implementado, medición formal pendiente

Nota. Elaboración propia. Fecha de corte: 12 de noviembre de 2026.

CAPÍTULO III. MARCO TEÓRICO

El marco teórico se organiza según las variables: primero los datos de partida, luego los modelos y su adaptación (variable independiente) y, por último, las medidas de exactitud y de calibración (variable dependiente).

3.1 Bases teóricas

Imágenes Sentinel-2 e índices de agua. La misión Sentinel-2 observa la superficie con un instrumento de 13 bandas, de 10, 20 y 60 m de resolución, y con dos satélites revisita el ecuador cada cinco días (European Space Agency, 2015, §1.1, p. 9). El producto de nivel 1C entrega reflectancia en el techo de la atmósfera en teselas de 110 × 110 km (Copernicus, s.f.). El agua refleja poco en el infrarrojo, a diferencia del suelo y de la vegetación; los índices NDWI (McFeeters, 1996) y MNDWI (Xu, 2006) aprovechan ese contraste:

$$\mathrm{NDWI} = \frac{\rho_{\mathrm{B3}} - \rho_{\mathrm{B8}}}{\rho_{\mathrm{B3}} + \rho_{\mathrm{B8}}}, \qquad \mathrm{MNDWI} = \frac{\rho_{\mathrm{B3}} - \rho_{\mathrm{B11}}}{\rho_{\mathrm{B3}} + \rho_{\mathrm{B11}}}, \tag{1}$$

donde ρ es la reflectancia de cada banda. Un umbral sobre estos índices es el método más simple para separar el agua y sirve aquí como referencia sin aprendizaje.

Segmentación semántica y U-Net. La segmentación semántica asigna una clase a cada píxel (Long et al., 2015). La U-Net combina un codificador y un decodificador simétricos con conexiones directas entre niveles, que recuperan el detalle espacial (Ronneberger et al., 2015); su

codificador puede ser una red residual (He et al., 2016). La pérdida de Dice optimiza el solapamiento entre predicción y referencia, lo que conviene cuando una clase ocupa pocos píxeles (Milletari et al., 2016).

Modelos fundacionales geoespaciales. Un modelo fundacional se entrena con datos amplios, por lo general con autosupervisión, y se adapta después a muchas tareas (Bommasani et al., 2021, §1, p. 3). Los geoespaciales son *Transformers* de visión (Dosovitskiy et al., 2021) preentrenados con imágenes satelitales. Prithvi-EO-2.0 se preentrenó por autocodificación enmascarada sobre imágenes HLS de 30 m (Szwarcman et al., 2024, §III-B), y TerraMind es un modelo generativo que relaciona varias modalidades, entre ellas Sentinel-2 de nivel 1C (Jakubik et al., 2025). Para segmentar, se les añade un decodificador y se ajustan con datos etiquetados (ajuste fino). La investigación los usa mediante la biblioteca TerraTorch (Gomes et al., 2025). Frente a la U-Net, estos modelos aportan un preentrenamiento mucho mayor, pero procesan la imagen en parches de 16 × 16 píxeles, lo que puede costar detalle en los bordes.

Cambio de dominio y adaptación no supervisada. Hay cambio de dominio cuando la distribución de los datos de entrenamiento (origen) difiere de la de aplicación (objetivo). El error en el objetivo queda acotado por el error en el origen más una medida de la divergencia entre ambas distribuciones (Ben-David et al., 2010, Teorema 2, p. 157). La adaptación no supervisada usa datos del objetivo sin etiquetas. Se consideran tres familias:

- **Alineación de la entrada.** La igualación de histogramas lleva la distribución de cada banda a la de otro conjunto (Gonzalez y Woods, 2018). La adaptación en el dominio de Fourier (FDA) reemplaza la amplitud de baja frecuencia de una imagen por la de otra y conserva su fase (Yang y Soatto, 2020).
- **Alineación de estadísticas internas.** AdaBN recalcula las estadísticas de las capas de normalización por lotes con datos del objetivo (Y. Li et al., 2018). Solo actúa sobre ese tipo de capas, que en los modelos fundacionales están únicamente en el decodificador.
- **Autoentrenamiento.** El modelo genera pseudoetiquetas en el objetivo y se reentrena con ellas (Zou et al., 2018), por lo general con un maestro de media móvil (Tarvainen y Valpola, 2017).

Métricas de exactitud. Con los verdaderos positivos (TP), falsos positivos (FP) y falsos negativos (FN) de la clase agua:

$$\text{IoU} = \frac{TP}{TP + FP + FN}, \qquad \text{precisión} = \frac{TP}{TP + FP}, \qquad \textit{recall} = \frac{TP}{TP + FN}. \tag{2}$$

El IoU es la medida habitual en segmentación (Everingham et al., 2010) y no premia acertar el fondo, que aquí es la clase mayoritaria.

Calibración e incertidumbre. Un modelo está calibrado cuando su confianza coincide con su frecuencia de acierto. El error de calibración esperado agrupa las predicciones en M intervalos

de confianza B_m y promedia la diferencia entre exactitud y confianza (Guo et al., 2017):

$$\text{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{n} \left|\text{acc}(B_m) - \text{conf}(B_m)\right| . \tag{3}$$

El escalado de temperatura divide las salidas del modelo por un escalar ajustado en validación (Guo et al., 2017), y los ensambles promedian las probabilidades de modelos entrenados con distintas semillas (Lakshminarayanan et al., 2017). La utilidad de la incertidumbre para señalar errores se mide con el área bajo la curva ROC (AUROC) al separar los píxeles mal clasificados de los correctos; 0.5 equivale al azar (Hendrycks y Gimpel, 2017).

Inferencia por remuestreo. El remuestreo *bootstrap* estima la variabilidad de un estadístico recalculándolo sobre muestras extraídas con reemplazo (Efron y Tibshirani, 1993). Cuando dos métodos se evalúan sobre los mismos recortes, el remuestreo pareado da el intervalo de confianza de su diferencia. Si el intervalo al 95 % incluye el cero, no se detecta una diferencia, lo que no demuestra que los métodos sean equivalentes.

3.2 Definición de términos

Ajuste fino. Entrenamiento adicional de un modelo preentrenado con datos etiquetados de una tarea.

Agua detectada. Píxeles que el modelo clasifica como agua (probabilidad mayor que 0.5); incluye el agua permanente.

Área inundada. Superficie de los píxeles que pasan de no agua a agua entre una imagen previa al evento y la fecha analizada.

***Buffer*.** Franja de recortes sin uso que separa los recortes de entrenamiento de los de validación y de prueba.

Cambio de dominio. Diferencia entre la distribución de los datos de entrenamiento y la de los datos en que se aplica el modelo.

Cota superior. Modelo entrenado con datos etiquetados del dominio objetivo; referencia de lo que se podría alcanzar con etiquetas.

Dominio de origen y dominio objetivo. Sen1Floods11 y las imágenes peruanas, respectivamente.

Ensamble. Promedio de las probabilidades de los modelos de las tres semillas.

Esquema de entrenamiento. Datos con que se entrena un modelo: solo Sen1Floods11, solo el Perú, o Sen1Floods11 seguido de ajuste fino en el Perú.

IoU de agua. Intersección sobre la unión de la clase agua (Ecuación 2), agregada sobre todos los píxeles etiquetados de una partición.

Recorte. Porción de imagen de 512 × 512 píxeles (5.12 × 5.12 km a 10 m); es la unidad de entrenamiento y de evaluación.

Tesela. Unidad de distribución de los productos Sentinel-2 de nivel 1C, de 110 × 110 km.

CAPÍTULO IV. METODOLOGÍA

La investigación tiene enfoque cuantitativo y sigue el método hipotético-deductivo: las hipótesis se fijaron antes de obtener los resultados y se contrastan con evidencia definida de antemano.

4.1 Tipo de investigación

Es una investigación aplicada, de desarrollo tecnológico: usa conocimiento existente sobre segmentación y adaptación de dominio para resolver un problema concreto, el mapeo del agua en la costa norte del Perú, y entrega un sistema como producto.

4.2 Nivel de investigación

El nivel es explicativo: se estudia el efecto del modelo y del método de adaptación sobre la calidad del mapeo, manipulando esos factores y manteniendo fijo lo demás. La causalidad que el diseño permite afirmar se limita a ese efecto, sobre estos datos. Las explicaciones de por qué un método funciona o falla se presentan como interpretación de los autores, apoyada en diagnósticos, y no como relaciones demostradas.

4.3 Métodos de trabajo

Para los objetivos primero y segundo se realizan experimentos computacionales controlados, que siguen el protocolo de tres niveles de la literatura de adaptación: el modelo sin adaptar, el modelo adaptado y el modelo entrenado con datos etiquetados del objetivo (cota superior). Para el tercer objetivo, el sistema se desarrolla de forma iterativa e incremental y se evalúa frente a requisitos fijados antes de implementarlo. Todo el trabajo se registra por corrida: configuración, semilla, versión del código y archivo de resultados.

4.4 Población y muestra

La población son las imágenes Sentinel-2 de nivel 1C de eventos de inundación. La unidad de análisis es el recorte de 512 × 512 píxeles, y las métricas se calculan sobre sus píxeles etiquetados. La muestra es no probabilística y tiene dos partes.

- **Sen1Floods11**, con sus particiones oficiales: 252 recortes de entrenamiento, 89 de validación y 90 de prueba. No se vuelve a dividir. Los 15 recortes de Bolivia no se usan.
- **Conjunto peruano**, construido en esta investigación: 1 291 recortes de 2023 (753 de entrenamiento, 174 de validación, 172 de prueba y 192 de *buffer*) y 204 recortes de 2017, usados solo como prueba en otro evento. De estos últimos, la evaluación principal usa los 101 que no se superponen con ubicaciones de entrenamiento de 2023.

Se incluyen los recortes dentro del área analizada por los mapas expertos; se excluyen de las métricas los píxeles bajo nubes gruesas, sin datos o fuera de esa área. Para medir el tiempo del sistema se usarán las seis teselas que cubren el área analizada por UNOSAT.

4.5 Tipo de diseño

El diseño es experimental para los objetivos primero y segundo. La variable independiente se manipula (arquitectura, esquema de entrenamiento, método de adaptación y tratamiento de la incertidumbre) y se mantienen fijos los datos, las particiones, las semillas, el preprocesamiento y la configuración congelada antes de la prueba. Las comparaciones son pareadas: todos los métodos se evalúan sobre los mismos recortes. Para el tercer objetivo, el diseño es una evaluación técnica frente a requisitos y un umbral de tiempo fijados de antemano. Las inferencias previstas son diferencias de IoU entre configuraciones con su intervalo de confianza; no se generalizan a otras regiones ni a otros sensores.

4.6 Técnicas e instrumentos de recolección de datos

Los datos son secundarios y públicos. Las imágenes se descargan del ecosistema Copernicus Data Space, y las etiquetas peruanas se generan con reglas fijas a partir de los mapas de UNOSAT (2023) y de Copernicus EMS (2017), sin etiquetado manual propio. Los instrumentos son los programas del repositorio de la investigación, versionados con *git*. El control de calidad comprende sumas de verificación SHA-256 de cada archivo, una revisión automática que compara cada etiqueta con el índice MNDWI y un programa que impide entrenar con recortes de validación o de prueba. Las fuentes, sus licencias y su trazabilidad se detallan en la Sección 6.1.

4.7 Técnicas e instrumentos de análisis y procesamiento de datos

Preparación. Las imágenes peruanas se llevan a la misma escala y al mismo orden de bandas que Sen1Floods11, y cada modelo usa su normalización oficial.

Modelado. Los tres modelos comparten decodificador, función de pérdida (Dice) y optimizador (AdamW), y se entrenan con las semillas 0, 1 y 2.

Evaluación. La métrica principal es el IoU de agua; se informan también la precisión, el *recall*, el mIoU, el ECE y el AUROC de detección de errores. Las diferencias entre métodos se expresan como diferencias pareadas con intervalos de confianza al 95 %, obtenidos con 2 000 réplicas de remuestreo de recortes.

Prevención de fugas de información. Las particiones peruanas se separan por bloques espaciales con *buffer*. Toda decisión de modelado se toma con las particiones de validación. Las configuraciones se congelan antes de la prueba, y cada partición de prueba se evalúa una so-

la vez. Los métodos de adaptación se ajustan solo con imágenes de entrenamiento sin sus etiquetas (Sección 6.4).

4.8 Etapas de intervención del estudio

1. **Diagnóstico.** Reproducción del estado del arte en Sen1Floods11 y análisis exploratorio de los datos.
2. **Diseño.** Construcción del conjunto peruano y definición del protocolo y de las hipótesis.
3. **Implementación.** Entrenamiento con datos peruanos, análisis de errores en la validación, adaptación de dominio y calibración.
4. **Evaluación.** Congelamiento de las configuraciones y evaluación única en las particiones de prueba.
5. **Desarrollo del sistema.** Implementación de la aplicación y evaluación técnica.
6. **Iteración y cierre.** Análisis complementarios, redacción y revisión.

CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS

5.1 Cronograma

La Tabla 4 presenta las actividades por semana del curso; la semana 9 corresponde a la del 9 al 13 de noviembre de 2026. El Anexo B muestra el diagrama de Gantt. Los dos autores son responsables de todas las actividades.

Tabla 4
Cronograma de actividades e hitos

Actividad o hito	Semanas	Producto verificable
Plan de investigación, preguntas e hipótesis	3–4	`docs/PLAN.md`, versionado antes de los resultados
Reproducción en Sen1Floods11	4–5	Tres modelos de origen con tres semillas; comparación con los valores publicados
Construcción del conjunto peruano	4–5	Ficha de datos y sumas de verificación de 2 990 archivos
Entrenamiento en el Perú y análisis de errores	4–5	Tabla de validación y registro de decisiones
Adaptación de dominio y calibración	5	Tabla de métodos en la validación peruana
Hito: congelamiento y evaluación única en prueba	5	`configs/frozen.yaml`; informe de prueba (16 de octubre de 2026)
Redacción de los capítulos I a III de la tesis	5–6	Capítulos auditados en el repositorio de la tesis

Actividad o hito	Semanas	Producto verificable
Desarrollo del sistema	6	Aplicación web en funcionamiento con datos reales de una tesela
Análisis de datos, variables e hiperparámetros	5–8	Cuatro cuadernos ejecutados
Hito: informe parcial y defensa intermedia	9	Este informe
Medición formal del sistema	10–11	Requisitos RF1 a RF7 y tiempos de seis teselas con tres repeticiones
Análisis complementarios	10–12	Optimismo de las etiquetas de 2017; importancia de bandas en los tres modelos
Redacción del capítulo III (sistema) y del capítulo IV	11–13	Capítulos en el repositorio de la tesis
Hito: plan de tesis aprobado	14	Constancia de aprobación
Introducción, resumen, anexos y revisión final	13–15	Borrador integral
Hito: borrador integral y defensa final	16	Borrador de la tesis y repositorio reproducible

Nota. Elaboración propia. Las actividades hasta la semana 9 están ejecutadas; las siguientes son planificadas.

5.2 Presupuesto

La investigación no compra equipos. El gasto monetario es el alquiler de una GPU para entrenar los modelos; los datos y el *software* son de acceso libre (Tabla 5).

Tabla 5
Presupuesto

Rubro	Cantidad	Costo estimado
Cómputo en GPU alquilada (NVIDIA RTX 4090, a 0.89 USD por hora)	Seis sesiones de entrenamiento, ya ejecutadas	Aproximadamente 32 USD
Computador para inferencia, análisis y desarrollo del sistema (Apple M4 Max, 36 GB)	1, propio de los autores	Sin costo para el proyecto
Imágenes Sentinel-2 y mapas de UNOSAT y Copernicus EMS	Datos públicos	0
Sen1Floods11 y modelos preentrenados	Acceso libre	0
Software (Python, PyTorch, TerraTorch)	Código abierto	0
Almacenamiento externo de puntos de control	44.5 GB	Menor; no registrado

Nota. Elaboración propia a partir del registro de corridas. El costo de GPU suma las lecturas de facturación de cada sesión (6.2, 4.9, 0.7, 4.56, 6.19 y 9.68 USD).

5.3 Financiamiento

La investigación se financia con recursos propios de los autores. No recibe financiamiento institucional ni externo.

PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL

6. Datos y material de estudio

El estudio usa dos conjuntos de recortes Sentinel-2 de nivel 1C con etiquetas de agua: el conjunto internacional Sen1Floods11, que es el dominio de origen, y un conjunto peruano construido en esta investigación a partir de mapas expertos, que es el dominio objetivo.

6.1 Origen, condiciones de uso y trazabilidad

La Tabla 6 resume las fuentes. Todas son públicas y no requirieron autorización.

Tabla 6
Origen y condiciones de uso de los datos

Datos	Origen	Condiciones de uso	Período	Limitaciones
Sen1Floods11, etiquetas manuales, versión 1.1	Bonafilia et al. (2020)	Acceso público	11 eventos	Ningún evento peruano
Imágenes Sentinel-2 L1C del Perú	Copernicus Data Space	Datos Copernicus, libres	22 de marzo y 1 de abril de 2023; 7 de abril de 2017	Nubes; dos líneas base de procesamiento
Mapas del ciclón Yaku	UNOSAT, producto FL20230321PER (United Nations Satellite Centre (UNOSAT), 2023a, 2023b)	CC BY-SA	Marzo y abril de 2023	Preliminares, sin validación de campo
Mapas del Niño Costero	Copernicus EMS, activación EMSR199 (Copernicus Emergency Management Service, 2017)	Datos Copernicus, libres	23 al 30 de marzo de 2017	Trazados sobre radar, de una a dos semanas antes de la imagen óptica

Nota. Elaboración propia.

Versión y trazabilidad. El conjunto peruano (versión 1) se congeló el 14 de octubre de 2026, antes de entrenar los modelos peruanos. Sus manifiestos fijan 2 990 archivos con sumas de verificación SHA-256, y un programa comprueba cualquier copia contra ellos. El 23 de octubre

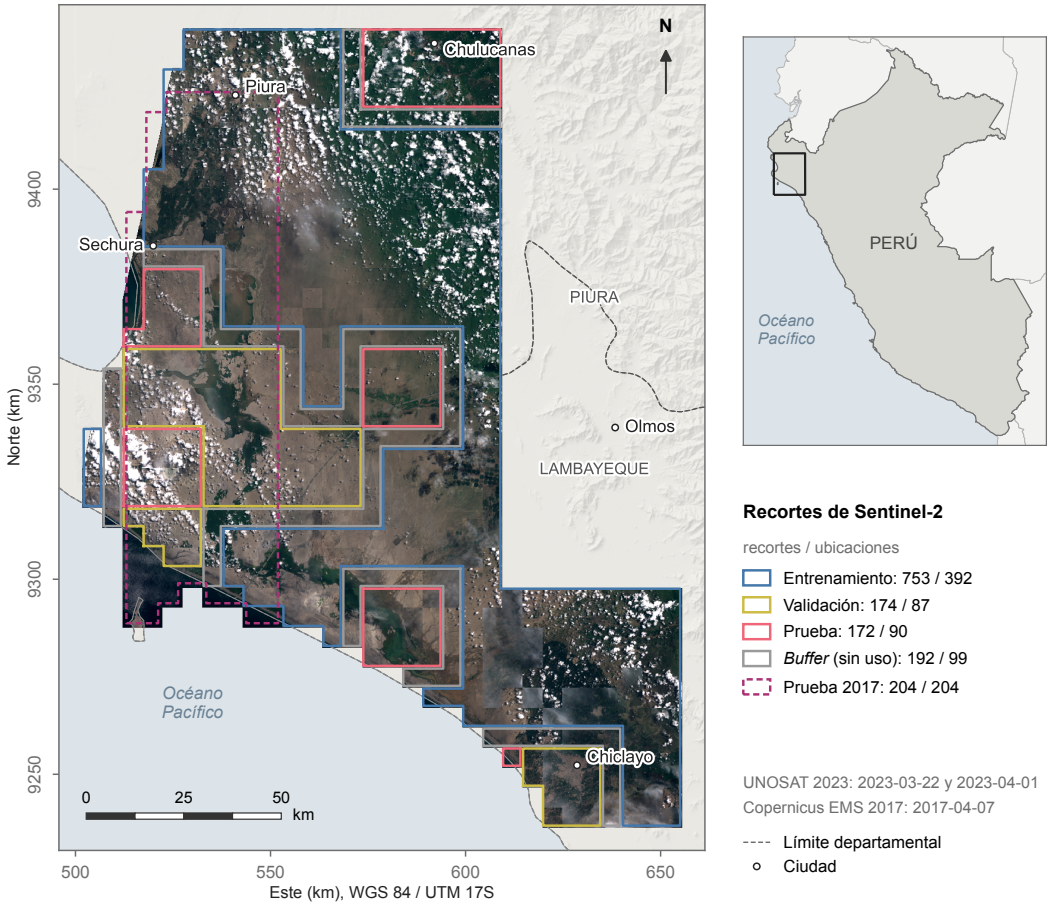
de 2026 los datos se reconstruyeron desde cero en un segundo computador y coincidieron bit a bit. El conjunto ocupa 5.3 GB, y Sen1Floods11, 977 MB.

6.2 Estructura, diccionario de datos y análisis exploratorio

Estructura. Cada recorte tiene 13 bandas en números digitales (reflectancia × 10 000), de 512 × 512 píxeles a 10 m, en la proyección UTM zona 17 sur. Cada píxel de la etiqueta vale 1 (agua), 0 (no agua) o −1 (ignorado); los ignorados no intervienen en la pérdida ni en las métricas. El Anexo C contiene el diccionario de datos. La Figura 1 muestra el área de estudio, y la Tabla 7, las particiones.

Figura 1

Área de estudio y particiones del conjunto peruano



Nota. Elaboración propia con datos modificados de Copernicus Sentinel-2 (2017 y 2023), Copernicus DEM GLO-30 y límites de Natural Earth. Los contornos indican la partición de cada ubicación; la línea discontinua, el conjunto de prueba de 2017.

Tabla 7
Particiones del conjunto peruano de 2023

Partición	Recortes	Ubicaciones	Recortes con agua	Agua (km²)	Seco (km²)	Ignorado
Entrenamiento	753	392	164	744	15 278	18.8 %
Validación	174	87	79	489	3 442	13.8 %
Prueba	172	90	63	366	3 144	22.2 %
Buffer (sin uso)	192	99	46	421	3 796	16.2 %

Nota. Elaboración propia a partir de los manifiestos congelados. «Recortes con agua»: más del 1 % de agua. «Ignorado»: proporción media de píxeles con etiqueta −1.

Análisis exploratorio. Se hizo solo con las particiones de entrenamiento y de validación; de las de prueba se leyeron únicamente metadatos. Sus hallazgos son los siguientes.

- **Desbalance.** El agua es minoritaria y su proporción cambia entre particiones: es el 4.6 % de los píxeles etiquetados en el entrenamiento peruano y el 12.4 % en la validación, frente al 9.5 y al 11.0 % en Sen1Floods11. El 64.5 % de los recortes de entrenamiento peruanos no tiene agua.
- **Cambio de dominio.** El suelo seco peruano es entre 1.38 y 1.68 desviaciones estándar más brillante que el de Sen1Floods11 en las bandas visibles y en B12. El agua, en cambio, difiere en 0.4 desviaciones estándar como máximo.
- **Anomalías en las etiquetas.** La comparación automática con el índice MNDWI marcó 32 recortes (2.5 %) con al menos 5 ha de desacuerdo claro, casi siempre píxeles etiquetados como secos que parecen agua.
- **Correlación entre bandas.** Es de 0.97 o más dentro de cada grupo espectral (visible, borde rojo e infrarrojo cercano, e infrarrojo de onda corta) y de 0.70 a 0.91 entre grupos.
- **Nubes.** Los detectores habituales (s2cloudless y la clasificación de escena de Sen2Cor) marcan como nube el desierto de Sechura, por lo que se usa una regla propia de nube gruesa.

Riesgos de sesgo. Los bloques de validación y de prueba se sortearon solo entre bloques con agua, por lo que tienen más agua que una tesela completa y su IoU no se extrapola sin más a escenas completas. Las etiquetas de 2017 conservan solo los píxeles en que el mapa de EMS y el índice MNDWI concuerdan, de modo que sus métricas pueden ser optimistas.

6.3 Ética, privacidad y seguridad

No se usan datos personales ni sensibles: las imágenes tienen 10 m de resolución y no permiten identificar personas, y los mapas de referencia son productos públicos. No se requiere anonimización ni consentimiento. Se respetan las licencias, con atribución a Copernicus y a UNOSAT. Las credenciales de descarga y de almacenamiento se guardan fuera del reposito-

rio. Los mapas que genera el sistema son resultados de investigación: no deben usarse para decidir sobre una emergencia sin la revisión de un especialista.

6.4 Preprocesamiento y control de fuga de información

Operaciones fijas, iguales para todas las particiones. No se ajustan con datos:

- retirar el desplazamiento de +1 000 que introdujo la línea base de procesamiento 04.00, para que las imágenes de 2023 sean comparables con las anteriores a 2022;
- la normalización oficial de entrada de cada modelo;
- la conversión de los polígonos expertos en etiquetas con reglas fijas, y la regla de nube gruesa (B02 > 4500 y B11 < 1.15 · B02, dilatada 5 píxeles).

Operaciones que se ajustan solo con datos de entrenamiento.

- Los pesos de los modelos, con la partición de entrenamiento de cada esquema.
- Los cuantiles de la igualación de histogramas, las amplitudes de FDA, las estadísticas de AdaBN y las pseudoetiquetas, con las 753 imágenes de entrenamiento peruanas sin sus etiquetas. El programa que las carga solo conoce las rutas de las imágenes y produce un error si se intenta abrir un archivo de etiquetas peruanas.
- La temperatura de calibración de las configuraciones adaptadas, con la validación de Sen1Floods11.

Uso de la validación y de la prueba. La validación de Sen1Floods11 elige la tasa de aprendizaje y la mejor época de los modelos de origen. La validación peruana elige la mejor época de los modelos entrenados en el Perú y el método de adaptación de cada modelo. Por eso los métodos de adaptación se ajustan sin etiquetas peruanas, pero su selección sí las usó: el procedimiento completo no prescinde de etiquetas locales. A las particiones de prueba solo se les aplican las operaciones ya ajustadas, una sola vez.

Separación espacial. La partición se hizo por bloques de 4 × 4 recortes (unos 20 km). Una ubicación pertenece a la misma partición en las dos fechas, y los recortes de entrenamiento que tocan uno de validación o de prueba se apartaron como *buffer*. El análisis exploratorio no encontró ninguna ubicación repetida entre particiones.

7. Protocolo experimental

El protocolo se definió antes de comparar resultados. Las hipótesis primera y segunda constan en el plan de investigación del 11 de octubre de 2026; la parte de la segunda referida a la adaptación se precisó el 14 de octubre, después del análisis de errores en la validación y antes de cualquier evaluación en prueba. La tercera hipótesis y los requisitos del sistema se fijaron el 16 de octubre de 2026, antes de implementarlo.

7.1 Preguntas de evaluación y criterios de éxito

Cada hipótesis específica se divide en afirmaciones que se contrastan por separado (Tabla 8). Una afirmación se confirma cuando la evidencia cumple el criterio en la dirección prevista, y se refuta cuando va en la dirección contraria con un intervalo que excluye el cero.

Tabla 8
Afirmaciones que se contrastan, métricas y criterios

N.°	Afirmación	Métrica	Criterio
1a	En Sen1Floods11 no se detecta una diferencia entre los modelos fundacionales y la U-Net	Diferencia pareada de IoU de agua en la prueba	El intervalo de confianza al 95 % incluye el cero
1b	En el Perú, los modelos fundacionales pierden menos IoU que la U-Net	Diferencia entre las caídas de IoU de Sen1Floods11 al Perú	Intervalo al 95 % por encima de cero
2a	Los errores se concentran en pocas condiciones (bordes de nubes, vegetación inundada, terreno desértico o costero)	Proporción de errores y de píxeles por condición	Proporción de errores de al menos el doble de la de píxeles (criterio fijado después de ver la validación)
2b	La adaptación mejora al modelo sin adaptar, sin llegar al modelo entrenado en el Perú	Diferencias pareadas de IoU de agua en la prueba	Intervalo por encima de cero frente al modelo sin adaptar, y por debajo de cero frente al entrenado en el Perú
2c	Los modelos son sobreconfiados; la temperatura y los ensambles reducen el ECE; la incertidumbre permite detectar errores	Temperatura ajustada, ECE y AUROC	Temperatura mayor que 1; ECE menor que el del modelo individual; AUROC mayor que 0.5
3	El sistema cumple sus requisitos y procesa una escena en un tiempo adecuado	Requisitos RF1 a RF7 cumplidos; tiempo por tesela	7 de 7 requisitos; mediana de tres repeticiones de 15 minutos o menos en cada una de las seis teselas

Nota. Elaboración propia. La afirmación 1a no fija un margen de equivalencia: un intervalo que incluye el cero solo indica que no se detectó una diferencia. El umbral de 15 minutos es un requisito operativo fijado por los autores.

Los requisitos funcionales son siete: seleccionar un evento o una fecha y un área (RF1); obtener la imagen Sentinel-2 (RF2); generar el mapa de probabilidad de agua con el ensamble de tres semillas (RF3); mostrar la incertidumbre y las zonas no observadas (RF4); superponer el mapa de referencia y mostrar las métricas de concordancia (RF5); calcular el área inundada por fecha (RF6), y exportar los mapas en GeoTIFF y GeoJSON (RF7).

7.2 Diseño de particiones y validación

La validación es de tipo *holdout* con particiones fijas: las oficiales en Sen1Floods11 y una partición por bloques espaciales en el Perú, complementada con una prueba en otro evento (Tabla 9). No se usa validación cruzada *K-fold*: Sen1Floods11 no se vuelve a dividir para que los resultados sean comparables con los publicados, y repetir cada configuración en K particiones de bloques peruanos multiplicaría el costo de GPU. En su lugar, cada configuración se entrena con las semillas 0, 1 y 2, y la variación por recortes se estima por remuestreo.

Tabla 9
Particiones y uso permitido

Conjunto	Criterio de separación	Tamaño y período	Uso permitido
Sen1Floods11, entrenamiento	Partición oficial	252 recortes	Entrenar los modelos de origen
Sen1Floods11, validación	Partición oficial	89 recortes	Elegir la tasa de aprendizaje y la mejor época; ajustar la temperatura
Sen1Floods11, prueba	Partición oficial	90 recortes	Evaluación única
Perú, entrenamiento	Bloques espaciales de 4 × 4 recortes	753 recortes; 2023	Entrenar los modelos peruanos; ajustar la adaptación sin leer las etiquetas
Perú, validación	Bloques espaciales, separados por *buffer*	174 recortes; 2023	Elegir la mejor época y el método de adaptación; análisis de errores
Perú, prueba	Bloques espaciales, separados por *buffer*	172 recortes; 2023	Evaluación única
Perú, *buffer*	Recortes de entrenamiento que tocan uno de evaluación	192 recortes; 2023	Ninguno
Perú 2017, prueba	Otro evento; sin contacto con ubicaciones de entrenamiento de 2023	101 recortes (204 en total); 2017	Evaluación única

Nota. Elaboración propia.

Prevención de contaminación. Las configuraciones elegidas se congelaron en un archivo versionado, con la suma de verificación de cada punto de control. El programa de evaluación se niega a procesar una partición de prueba si la configuración no está congelada, si un punto de control no coincide con su suma, si hay cambios sin registrar en el código o si la predicción ya existe. Una limitación conocida es que 57 de los 101 recortes de 2017 ocupan la misma celda

que un recorte de validación de 2023: la prueba de 2017 es una prueba en otro evento, no en otra región.

7.3 Métricas y análisis estadístico

Métrica primaria. El IoU de agua, agregado sobre todos los píxeles etiquetados de la partición, como proporción con tres decimales. La predicción es agua si su probabilidad supera 0.5, sin ajustar el umbral. Se prefiere a la exactitud porque el agua es minoritaria: un modelo que no detectara agua tendría una exactitud alta.

Métricas secundarias. Precisión, *recall* y mIoU; el ECE, en porcentaje, con 15 intervalos de igual ancho, sobre todos los píxeles y a 10 píxeles o menos del borde del agua; y el AUROC de detección de errores.

Incertidumbre y agregación. Cada resultado se informa como media ± desviación estándar sobre tres semillas. Las comparaciones usan diferencias pareadas con intervalos de confianza al 95 % por remuestreo de recortes (2 000 réplicas). El remuestreo cuantifica la variación por recortes; no remuestrea las semillas ni corrige la dependencia espacial entre recortes vecinos. Para el ECE y el AUROC no se calcularon intervalos.

Criterio de comparación. Una diferencia se considera detectada si su intervalo excluye el cero. Si lo incluye, se informa que no se distingue de cero, sin afirmar equivalencia.

7.4 *Baseline* y variantes

El *baseline* mínimo es un umbral del índice MNDWI, sin aprendizaje. El *baseline* sólido es la U-Net entrenada en Sen1Floods11 y aplicada al Perú sin adaptar, que es lo que se obtendría hoy ante una inundación nueva. Las variantes cambian un factor por vez (Tabla 10). Los controles comunes son los datos y las particiones, el decodificador, la pérdida de Dice, el optimizador AdamW, la parada temprana con paciencia de 20 épocas y las semillas 0, 1 y 2.

Tabla 10
Baseline y variantes

ID	Modelo o configuración	Diferencia frente al *baseline*	Hipótesis de cambio
B0	Umbral de MNDWI	Sin aprendizaje	Referencia mínima
B1	U-Net (ResNet-34) entrenada en Sen1Floods11, sin adaptar	Ninguna	Referencia sin adaptación

ID	Modelo o configuración	Diferencia frente al *baseline*	Hipótesis de cambio
V1	U-Net con igualación de histogramas en el entrenamiento	Las imágenes de entrenamiento se llevan a la distribución de brillo peruana	Si el problema es el brillo del suelo seco, igualar las distribuciones elimina los falsos positivos
V2	U-Net con FDA en el entrenamiento	Se transfiere la amplitud de baja frecuencia de una imagen peruana	Transferir solo el estilo global conserva la estructura de la imagen
V3	U-Net con AdaBN	Se recalculan las estadísticas de normalización con imágenes peruanas	Corregir las estadísticas internas basta, sin reentrenar
V4	U-Net o TerraMind con autoentrenamiento	Pseudoetiquetas peruanas con un maestro de media móvil	El modelo aprende del propio dominio objetivo
V5	TerraMind v1-B, sin adaptar y con alineación	Codificador *Transformer* preentrenado	El preentrenamiento geoespacial reduce la caída de IoU
V6	Prithvi-EO-2.0 300M, sin adaptar y con alineación	Codificador *Transformer* preentrenado; seis bandas	El preentrenamiento geoespacial reduce la caída de IoU
R1	Los tres modelos entrenados con datos etiquetados del Perú	Usa etiquetas peruanas	Cota superior
R2	Los tres modelos con ajuste fino desde Sen1Floods11	Pesos iniciales de origen	Partir de Sen1Floods11 ayuda al entrenamiento peruano

Nota. Elaboración propia.

La Tabla 11 detalla la configuración de los tres modelos. Los dos modelos fundacionales se ajustan por completo, codificador incluido.

Tabla 11
Configuración de los modelos

	U-Net	TerraMind v1-B	Prithvi-EO-2.0 300M
Codificador	ResNet-34 (ImageNet)	ViT multimodal	ViT, preentrenado con imágenes HLS
Bandas de entrada	13 bandas L1C	13 bandas L1C	B2, B3, B4, B8A, B11 y B12
Decodificador	U-Net	U-Net	U-Net
Tamaño de lote	8	8	4
Decaimiento de pesos	0.05	0.01	0.1
Tasa de aprendizaje, origen	3×10^{-4}	5×10^{-5}	1×10^{-4}
Tasa de aprendizaje, Perú	1×10^{-4}	2×10^{-5}	1×10^{-4}

Nota. Elaboración propia a partir de los archivos de configuración de cada corrida.

7.5 Ingeniería de atributos o componentes

Atributos. Se probó si las variables diseñadas a mano aportan frente a las bandas crudas, con un clasificador por píxel de *gradient boosting* y cuatro conjuntos de variables: las 13 bandas; ocho índices espectrales; bandas e índices, y todo lo anterior con cinco variables de contexto local. Se evaluó en la validación peruana, sobre un cuarto de los píxeles y con tres semillas.

- Con datos etiquetados del Perú, las variables diseñadas no añaden información: las bandas crudas obtienen 0.930 ± 0.001, y las bandas con índices y contexto, 0.929 ± 0.005.
- Sin datos etiquetados del Perú, los clasificadores entrenados en Sen1Floods11 obtienen de 0.71 a 0.74 y confunden el desierto con agua (precisión de 0.72 a 0.74). Un umbral de MNDWI ajustado en Sen1Floods11 obtiene 0.836, igual que la U-Net sin adaptar.

Por ello, los modelos profundos reciben las bandas crudas, y los componentes que se varían son los de la adaptación: la transformación de las imágenes de entrenamiento, las estadísticas de normalización y las pseudoetiquetas. Ese umbral de MNDWI se definió después de la evaluación única en prueba, así que queda como resultado exploratorio y no se evaluará en prueba.

Importancia de las variables. Una descomposición de la varianza del IoU de validación indica que el esquema de entrenamiento es el factor que más pesa ($\eta^2 = 0.526$), por encima de la arquitectura (0.177) y de su interacción (0.169). Por permutación de bandas, la U-Net entrenada en el Perú depende sobre todo de la banda B11, del infrarrojo de onda corta: al permutarla, su IoU baja de 0.940 a casi cero. Ambos análisis usan solo la validación; el segundo, una sola semilla.

7.6 Optimización y presupuesto de búsqueda

La búsqueda de hiperparámetros se limitó por el costo de GPU (Tabla 12). Toda la selección usa particiones de validación; ninguna usa las de prueba.

Tabla 12
Espacio de búsqueda, estrategia y presupuesto

Parámetro	Rango u opciones	Estrategia	Presupuesto
Tasa de aprendizaje de los modelos de origen	U-Net: 3×10^{-5}, 10^{-4}, 3×10^{-4}, 10^{-3}. TerraMind: 10^{-5}, 2×10^{-5}, 5×10^{-5}. Prithvi: 3×10^{-5}, 10^{-4}, 3×10^{-4}	Búsqueda en malla, semilla 0; selección en la validación de Sen1Floods11	10 corridas de hasta 100 épocas
Límite de épocas	100 o 200	Se elevó a 200 en las corridas finales de origen, porque dos corridas del barrido tuvieron su mejor época cerca del límite	9 corridas finales; ninguna llegó al límite
Método de adaptación por modelo	AdaBN; igualación de histogramas o FDA, en la inferencia o en el entrenamiento; autoentrenamiento	Cada método, con su configuración fijada de antemano y tres semillas; selección en la validación peruana	Dos sesiones de GPU (6.19 y 9.68 USD)
Igualación de histogramas o FDA en el entrenamiento	Dos opciones	Regla fijada antes de las corridas: mayor IoU de validación de la semilla 0	Incluido en la fila anterior
Autoentrenamiento (peso y umbral de las pseudoetiquetas)	Malla de diagnóstico, semilla 0	No se usó para seleccionar	Incluido en la primera sesión
Modelos entrenados en el Perú	Tasa de la configuración base	Sin búsqueda	Pendiente (Sección 9.3)

Nota. Elaboración propia. Quedaron fijos el decaimiento de pesos, el tamaño de lote, la función de pérdida, el decodificador, el planificador de la tasa de aprendizaje y el parámetro β de FDA (0.01).

En la validación de Sen1Floods11, el barrido subió el IoU de agua de la U-Net de 0.819 a 0.832 y el de TerraMind de 0.817 a 0.835; Prithvi ya usaba su mejor tasa. En la U-Net, la ventaja de la tasa elegida sobre la segunda (0.017) es igual a la diferencia que se obtuvo al repetir una misma corrida, por lo que no se afirma que sea la mejor. La tasa de TerraMind está en el borde de su malla.

7.7 Reproducibilidad y registro de experimentos

- **Repositorio.** `https://github.com/gersongams/peru-flood-segmentation`. Cada corrida guarda su configuración resuelta, sus métricas por época y un archivo con el *commit*, el estado del árbol de trabajo, el dispositivo y las versiones.
- **Registros.** El registro de corridas (`docs/EXPERIMENT_LOG.md`) anota cada corrida y evaluación con su *commit*, su carpeta y su archivo de resultados; el de decisiones metodológicas (`docs/METHODS_NOTES.md`) anota el porqué, las alternativas descartadas y las correcciones. El Anexo D resume las corridas principales.
- **Datos.** Conjunto peruano versión 1, fijado con sumas SHA-256 (`docs/peru_v1_checksums.txt`); Sen1Floods11 versión 1.1 con sus particiones oficiales.
- **Dependencias.** Python 3.12, PyTorch 2.14.0, Lightning 2.6.6, TerraTorch 1.2.13 y TorchGeo 0.9.0, fijadas en `uv.lock`.
- **Hardware.** Entrenamiento en una GPU NVIDIA RTX 4090 alquilada, con precisión mixta de 16 bits. Inferencia y análisis en un computador Apple M4 Max, con precisión de 32 bits.
- **Configuración congelada.** `configs/frozen.yaml`: 14 grupos y 42 corridas, con la suma de verificación de cada punto de control.

Los comandos siguientes reproducen el *baseline*, la variante V1 y la evaluación:

```
# Baseline B1 (commit 8a8fee4)
DATASET=s1f11 RUN_NAME=s1f11_src_unet bash scripts/cloud/run_queue.sh unet "0 1 2" \
  --optimizer.init_args.lr=3e-4 --trainer.max_epochs=200
# Variante V1 (commit e8001a4)
DATASET=s1f11 RUN_NAME=s1f11_trhm_unet bash scripts/cloud/run_queue.sh unet "0 1 2" \
  --optimizer.init_args.lr=3e-4 --trainer.max_epochs=200 \
  -c configs/phaseD/train_hm.yaml --data.init_args.num_workers=8
# Evaluacion unica y puntuacion de la configuracion congelada (commit f1f61d6)
uv run python scripts/evaluate_frozen.py peru-test
uv run python scripts/score_frozen.py peru-test
```

El entrenamiento en GPU no se reproduce bit a bit: repetir la semilla 0 del *baseline* con la misma configuración cambió su IoU de validación de 0.833 a 0.816. Por eso las diferencias menores de unas dos centésimas de IoU se interpretan con cautela.

8. Resultados parciales y evidencia

El período de corte es el 12 de noviembre de 2026. Todas las cifras de esta sección provienen de corridas ejecutadas y registradas. Las evaluaciones de modelos están completas: cada partición de prueba se evaluó una sola vez, el 16 de octubre de 2026, y no se prevé volver a usarlas. Lo que falta medir es el sistema (afirmación 3), del que solo se informan comprobaciones preliminares.

8.1 Estado de implementación del *pipeline*

La Tabla 13 resume el estado de cada etapa del *pipeline*.

Tabla 13
Estado de implementación por etapa

Etapa	Estado	Prueba de ejecución o salida verificable
Descarga y verificación de Sen1Floods11	Completa	1 338 archivos; particiones de 252, 89 y 90 recortes verificadas
Construcción del conjunto peruano	Completa	Manifiestos con SHA-256; reconstrucción idéntica en un segundo computador
Entrenamiento de los tres modelos, tres esquemas	Completa	Tres semillas por configuración; `outputs/runs_cloud/`, `outputs/s1f11_src_*/`
Métodos de adaptación	Completa	Tabla de la validación peruana, `outputs/phaseD/dev_table.md`
Calibración e incertidumbre	Completa	`outputs/phaseD/test/calibration.md`
Congelamiento y evaluación única en prueba	Completa	33 corridas por partición de prueba; `docs/phaseD_test.md`
Remuestreo e intervalos de confianza	Completa	`outputs/phaseD/test/bootstrap_diffs.csv`
Sistema: procesamiento de una tesela completa	Implementada	Tesela 17MNP en ocho fechas de 2023 y una de 2017
Sistema: aplicación web (seis pantallas)	Implementada	Servidor y aplicación en funcionamiento con datos reales
Sistema: requisitos RF1 a RF7	Parcial	RF1, RF3 y RF5 superan sus comprobaciones preliminares; falta la medición formal de los siete
Sistema: tiempo por tesela	Pendiente	Programa de medición escrito; exige una versión etiquetada del código

Nota. Elaboración propia.

Las comprobaciones preliminares del sistema son tres. En RF3, el mapa de la tesela coincide con el de los 49 recortes de prueba que contiene (IoU entre ambos de 0.9999, con un umbral mínimo de 0.95). En RF5, el sistema reproduce las métricas de la evaluación congelada sobre los 172 recortes de prueba (IoU 0.828, precisión 0.966 y *recall* 0.853). En RF1, el área seleccionada llega al registro del servidor. Son corridas de desarrollo: no constituyen la medición de la tercera hipótesis, que sigue pendiente.

8.2 Comparación cuantitativa del *baseline* y variantes

La Tabla 14 compara el *baseline* y las variantes en la validación peruana, por semilla, y en la prueba de 2023. Incluye los resultados desfavorables.

Tabla 14

IoU de agua del baseline y de las variantes

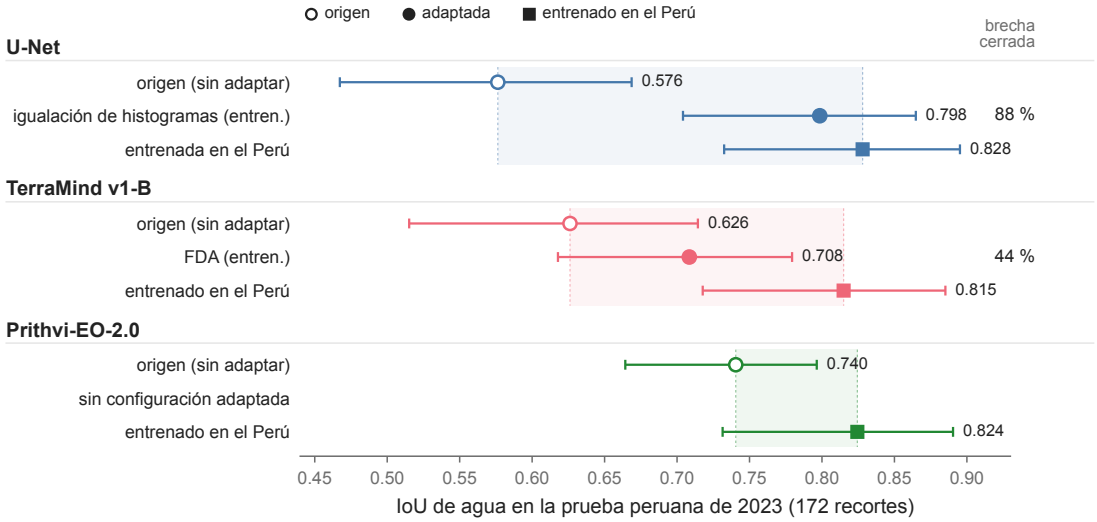
Experimento	Validación, semillas 0, 1 y 2	Validación, media ± DE	Prueba de 2023, media [IC 95 %]	Tiempo o costo	Decisión
B0: MNDWI >0	—	0.486	No evaluado	Casi nulo	Referencia mínima
B1: U-Net de origen	0.843, 0.854, 0.811	0.836 ± 0.022	0.576 [0.467, 0.669]	336 a 648 s por corrida	*Baseline*
V1: U-Net, igualación de histogramas (entren.)	0.915, 0.910, 0.911	0.912 ± 0.003	0.798 [0.704, 0.865]	+0.11 s por recorte al entrenar	Se adopta para la U-Net
V2: U-Net, FDA (entren.)	0.725, 0.501, 0.619	0.615 ± 0.112	No evaluado	+0.26 s por recorte al entrenar	Se descarta
V3: U-Net, AdaBN	0.905, 0.907, 0.878	0.897 ± 0.016	0.731 [0.624, 0.812]	Una pasada sin entrenar	Secundaria
V4: U-Net, autoentrenamiento	0.914, 0.844, 0.698	0.818 ± 0.110	No evaluado	Sesión de 6.19 USD	Se descarta
V5: TerraMind de origen	0.764, 0.598, 0.746	0.703 ± 0.091	0.626 [0.515, 0.714]	n. r.	Referencia
V5: TerraMind, FDA (entren.)	0.835, 0.837, 0.837	0.836 ± 0.001	0.708 [0.618, 0.779]	Sesión de 9.68 USD	Se adopta para TerraMind
V5: TerraMind, igualación de histogramas (entren.)	0.817, 0.841, 0.874	0.844 ± 0.028	0.721 [0.609, 0.802]	Sesión de 9.68 USD	Secundaria
V4: TerraMind, autoentrenamiento	0.470, 0.467, 0.516	0.484 ± 0.027	No evaluado	Sesión de 6.19 USD	Se descarta
V6: Prithvi de origen	0.869, 0.870, 0.871	0.870 ± 0.001	0.740 [0.664, 0.796]	Sesión de 9.68 USD	Se adopta para Prithvi
V6: Prithvi, igualación de histogramas (entren.)	0.869, 0.861, 0.849	0.860 ± 0.010	No evaluado	Sesión de 9.68 USD	Se descarta
R1: U-Net entrenada en el Perú	0.940, 0.943, 0.941	0.941 ± 0.002	0.828 [0.732, 0.895]	22 a 35 min por corrida	Cota superior
R1: TerraMind entrenado en el Perú	0.927, 0.924, 0.928	0.927 ± 0.002	0.815 [0.718, 0.885]	22 a 35 min por corrida	Cota superior
R1: Prithvi entrenado en el Perú	0.921, 0.923, 0.922	0.922 ± 0.001	0.824 [0.731, 0.890]	22 a 35 min por corrida	Cota superior

Nota. Elaboración propia. Validación: 174 recortes; prueba: 172 recortes, evaluación única. DE: desviación estándar sobre tres semillas. El intervalo de cada fila es el del IoU medio de las semillas por remuestreo de recortes y no sirve para comparar filas, que se comparan con diferencias pareadas (véase el texto). «No evaluado»: la configuración se descartó en la validación y, según el protocolo, no pasó a la prueba. La fila V3 muestra los valores obtenidos inicialmente; con el programa de evaluación congelado, su media es 0.899 ± 0.012. n. r.: no registrado por separado.

Diferencias pareadas en la prueba de 2023. La variante V1 superó al *baseline* en +0.222 [0.132, 0.309], a la U-Net con AdaBN en +0.068 [0.005, 0.138] y a Prithvi de origen, el mejor modelo sin adaptar, en +0.058 [0.013, 0.105]. Quedó por debajo de la U-Net entrenada en el Perú en −0.030 [−0.048, −0.013]. TerraMind con FDA en el entrenamiento superó a su modelo de origen en +0.082 [0.016, 0.156]. La Figura 2 muestra qué parte de la brecha entre cada modelo de origen y su versión peruana cerró la adaptación: el 88 % en la U-Net y el 44 % en TerraMind.

Figura 2

IoU de agua en la prueba de 2023 antes y después de la adaptación



Nota. Elaboración propia. Media de tres semillas con el intervalo de confianza al 95 % de cada fila. La franja sombreada va del modelo de origen al entrenado en el Perú; a la derecha, la proporción de la brecha cerrada.

Sen1Floods11. En la prueba oficial, los modelos de origen obtuvieron 0.833 ± 0.005 (U-Net), 0.820 ± 0.012 (Prithvi) y 0.819 ± 0.014 (TerraMind). Las diferencias pareadas no se distinguen de cero: U-Net menos Prithvi, +0.013 [−0.022, 0.062]; U-Net menos TerraMind, +0.015 [−0.018, 0.051]. Los dos modelos fundacionales reproducen los valores publicados por sus autores con una diferencia menor de 0.005.

Resultado desfavorable: el evento de 2017. En la prueba de 2017 el orden se invierte. Los modelos de origen (0.917 a 0.937) superaron a las configuraciones adaptadas (0.831 a 0.887) y a los modelos entrenados en el Perú (0.878 a 0.892). La variante V1 quedó por debajo del *baseline* en −0.063 [−0.083, −0.046], y TerraMind adaptado, por debajo de su modelo de origen en −0.103 [−0.175, −0.048]. Las etiquetas de 2017 conservan solo los píxeles en que EMS y el índice MNDWI concuerdan, por lo que estas métricas pueden ser optimistas y miden sobre todo el *recall*.

8.3 Ablaciones y análisis de sensibilidad

La Tabla 15 reúne los cambios controlados: en cada fila cambia un solo componente.

Dos resultados quedan fuera de la tabla. FDA aplicado en la inferencia fracasó en los tres modelos (IoU cercano a 0.01): al reemplazar la amplitud de frecuencia cero cambia la media de cada banda por separado y borra el contraste que distingue al agua. Y ningún método mejoró a los tres modelos: Prithvi, el mejor sin adaptar, empeoró en media con todos los métodos probados.

Tabla 15

Ablaciones y análisis de sensibilidad

Componente cambiado	Control	Resultado	Interpretación
Imágenes de entrenamiento con histogramas igualados (U-Net)	*Baseline* B1	Validación: 0.836 a 0.912; la precisión sube de 0.848 a 0.962 y el *recall* baja de 0.985 a 0.946	La mejora viene de eliminar falsos positivos sobre el desierto
FDA en el entrenamiento	Modelo de origen	U-Net: 0.836 a 0.615. TerraMind: 0.703 a 0.836	El efecto del método depende de la arquitectura
AdaBN	Modelo de origen	U-Net: 0.836 a 0.897. TerraMind: 0.703 a 0.656. Prithvi: 0.870 a 0.867	Ayuda donde hay normalización por lotes en el codificador
Pasada de AdaBN antes de evaluar el autoentrenamiento (*post hoc*)	Autoentrenamiento según el protocolo	Sin la pasada: U-Net 0.818 a 0.877; TerraMind 0.484 a 0.758	Esa pasada explica la mayor parte de la caída de TerraMind; aun sin ella, el método queda por debajo de la alineación
Pesos iniciales de Sen1Floods11 antes de entrenar en el Perú	Entrenamiento solo peruano	Prueba de 2023: +0.001 [−0.003, 0.005], −0.001 [−0.006, 0.003] y −0.002 [−0.006, 0.002]	No se detecta una diferencia; con datos etiquetados del Perú, el punto de partida importa poco
Tasa de aprendizaje de TerraMind (2×10^{-5} a 5×10^{-5})	Tasa original	Validación de Sen1Floods11: 0.814 ± 0.015 a 0.835 ± 0.001. Validación peruana: 0.692 ± 0.100 a 0.703 ± 0.091	Optimizar en el origen no resuelve el cambio de dominio
Excluir la franja de un píxel junto al borde del agua	Todos los píxeles	La ventaja de la U-Net sobre los modelos fundacionales baja de 0.015–0.020 a 0.003–0.004	Parte de la diferencia refleja la resolución del borde y la precisión de la etiqueta
Excluir los seis recortes de prueba con etiqueta dudosa	Todos los recortes	Todas las filas suben entre 0.005 y 0.016	El único cambio de orden se da entre dos filas de TerraMind que distan 0.003
Permutar una banda de entrada (U-Net peruana, semilla 0)	Sin permutar: 0.940	B11: caída de 0.88. B8A: 0.37. B05: 0.33. B04, B06 y B10: menos de 0.01	El modelo depende del infrarrojo de onda corta, que separa el agua de la arena

Nota. Elaboración propia. IoU de agua en la validación peruana, salvo donde se indica la prueba. Las tres diferencias de la quinta fila corresponden a la U-Net, TerraMind y Prithvi.

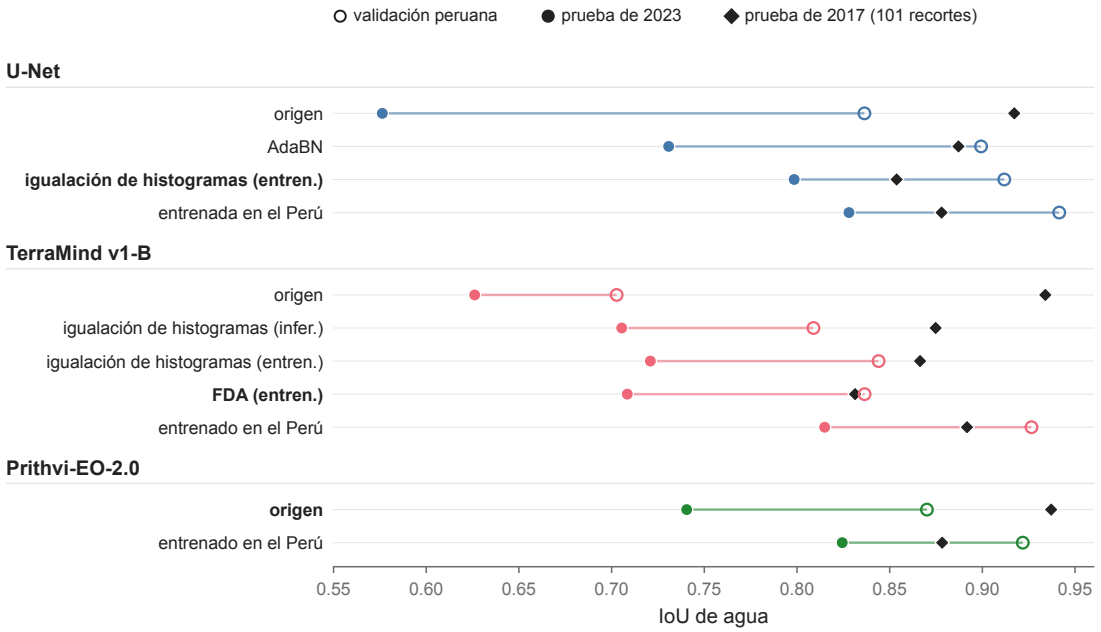
8.4 Sobreajuste, errores y robustez

Brecha entre validación y prueba. En Sen1Floods11, los modelos fundacionales perdieron entre 0.011 y 0.016 de la validación a la prueba, y la U-Net no perdió; esa diferencia estima el optimismo de haber seleccionado con la validación. En el Perú, las configuraciones principales y los modelos entrenados en el Perú perdieron entre 0.10 y 0.13 (la U-Net peruana bajó de 0.941 a 0.828). Como la caída afecta por igual a modelos adaptados y a modelos entrenados

con etiquetas, se atribuye sobre todo a que los bloques de prueba son más difíciles o están etiquetados de otro modo, y no a un sobreajuste de la adaptación. La Figura 3 muestra los tres valores de cada configuración.

Figura 3

IoU de agua en la validación y en las dos particiones de prueba



Nota. Elaboración propia. Media de tres semillas. Prueba de 2017: 101 recortes sin contacto con ubicaciones de entrenamiento de 2023; sus etiquetas conservan solo los píxeles en que EMS y el índice MNDWI concuerdan y miden sobre todo el *recall*.

Curvas de aprendizaje. No se estudió cuántos datos peruanos necesita cada modelo. Sobre la duración del entrenamiento, las tres corridas de TerraMind en el Perú alcanzaron el límite de 100 épocas; una repetición de la semilla 0 con límite de 200 se detuvo sola y obtuvo el mismo IoU de validación (0.927 frente a 0.928), de modo que el límite no restringe ese resultado.

Variabilidad. La desviación entre semillas es pequeña en los modelos entrenados en el Perú (0.001 a 0.002) y grande en algunos modelos de origen: TerraMind sin adaptar tiene 0.091, con una semilla en 0.598. La adaptación la reduce: a 0.003 en la U-Net con igualación de histogramas y a 0.001 en TerraMind con FDA.

Errores por condición. Los errores de los modelos de origen en el Perú son sobre todo falsos positivos: su *recall* supera 0.97, pero su precisión es de 0.847 (U-Net), 0.714 (TerraMind) y 0.887 (Prithvi). En los modelos entrenados en el Perú, la franja de un píxel junto al borde del agua reúne el 2.9 % de los píxeles y entre el 58.6 y el 66.3 % de los errores, y el agua permanente, el 2.5 % de los píxeles y entre el 12.0 y el 14.3 % de los errores. Las dos condiciones más difíciles son el agua de bajo contraste (NDWI entre −0.1 y 0.1), donde el IoU de los modelos peruanos baja a 0.45–0.53, y los cuerpos de agua menores de 1 ha, que se detectan con un *recall* de 45 a 58 %.

Casos de fallo. Una parte de los errores son errores de la etiqueta. Entre los diez recortes de validación con más errores, que reúnen el 32 % de ellos, la inspección visual encontró agua oscura etiquetada como seca y etiquetas con huecos dentro de zonas inundadas.

Costo de la adaptación. La igualación de histogramas elimina los falsos positivos del desierto, pero pierde agua tenue. En 2017, con MNDWI entre 0.1 y 0.3, el *recall* fue de 0.85 para Prithvi de origen y de 0.13 para la variante V1 (diagnóstico *post hoc*). Esa pérdida explica la inversión del orden en 2017.

Calibración. Todos los modelos resultaron sobreconfiados: las temperaturas ajustadas en la validación de Sen1Floods11 fueron mayores que 1 en las configuraciones congeladas (de 1.24 a 3.23). En la prueba de 2023, el ensamble con escalado de temperatura redujo el ECE de la variante V1 de 1.96 a 0.60 % sobre todos los píxeles, y de 16.88 a 12.81 % cerca del borde del agua. El AUROC de detección de errores de las configuraciones congeladas fue de 0.598 a 0.783. La incertidumbre, sin embargo, no señala los fallos dominantes: en el agua de bajo contraste y en los cuerpos pequeños, la U-Net y Prithvi entrenados en el Perú se equivocan con alta confianza (AUROC de 0.41 a 0.56 en la validación).

8.5 Interpretación y amenazas a la validez

Interpretación. El cambio de dominio entre Sen1Floods11 y la costa peruana está en el fondo seco más que en el agua, lo que es coherente con que los errores de los modelos de origen sean falsos positivos y con que funcionen los métodos que corrigen la distribución de la entrada. El método útil depende de la arquitectura, y el veredicto sobre la adaptación depende de la referencia: mejora frente a las etiquetas de 2023 y empeora frente a las de 2017, que premian el agua tenue. Estas explicaciones son coherentes con los datos, pero no se contrastaron con una referencia independiente.

La Tabla 16 resume el estado de la contrastación de las hipótesis.

Tabla 16

Estado de la contrastación de las hipótesis específicas

N.°	Evidencia principal	Veredicto
1a	Los dos intervalos pareados en Sen1Floods11 incluyen el cero	Coherente con la hipótesis; no se detectó una diferencia
1b	Diferencia de caídas: Prithvi 0.177 [0.102, 0.253]; TerraMind 0.064 [0.001, 0.120], con semillas que se solapan con las de la U-Net	Se confirma parcialmente (Prithvi); intervalo calculado después de la prueba
2a	De las tres condiciones previstas, solo la vegetación inundada alcanza el criterio, en dos modelos y con menos del 1 % de los errores; la mayor concentración está en el borde del agua	Respaldo exploratorio parcial
2b	Se cumple en 2023 para la U-Net y TerraMind; se invierte en 2017; Prithvi no tiene configuración adaptada	Se confirma en 2023; se refuta frente a la referencia de 2017
2c	Se cumple en todas las configuraciones congeladas	Se confirma, con excepciones fuera de ellas
3	Comprobaciones preliminares de RF1, RF3 y RF5	Pendiente de medición

Nota. Elaboración propia. La afirmación 2a usa la validación y un criterio fijado después de ver los resultados, por lo que es exploratoria.

Amenazas a la validez.

- **Tamaño de la muestra.** Hay tres semillas por configuración, una sola partición espacial y dos eventos de una misma región. Los intervalos de cada fila son amplios porque pocos recortes grandes concentran buena parte del agua; por eso las conclusiones se apoyan en diferencias pareadas.
- **Contaminación.** Las pruebas se evaluaron una sola vez con configuraciones congeladas. Queda una dependencia: la prueba de 2017 comparte gran parte de su zona con la validación de 2023, con la que se seleccionaron las configuraciones. El resultado de 2017 se mantiene al excluir los recortes cercanos a esa validación.
- **Generalización.** Los resultados no se extienden sin más a otras regiones, sensores o eventos. Las particiones de evaluación tienen más agua que una tesela completa.
- **Reproducibilidad.** El entrenamiento en GPU no es reproducible bit a bit, y dos de las 33 predicciones de validación (U-Net con AdaBN) no se reprodujeron exactamente con el programa de evaluación congelado; ninguna decisión depende de ellas.
- **Interpretabilidad.** La importancia por permutación mide cuánto depende el modelo de una banda, no una relación causal, y se calculó con una sola semilla y solo para la U-Net.
- **Sesgos de las etiquetas.** Las etiquetas de 2023 son preliminares y las de 2017 solo incluyen los píxeles concordantes; los dos eventos no miden lo mismo. Los métodos de adaptación se ajustan sin etiquetas peruanas, pero se seleccionaron con la validación peruana etiquetada.

9. Conclusiones del avance y próximos pasos

Los objetivos primero y segundo cuentan con evidencia completa; el tercero tiene el sistema implementado y su evaluación pendiente.

9.1 Conclusiones sustentadas por evidencia

Lo que se puede concluir hoy.

1. En Sen1Floods11 no se detectó una diferencia de IoU de agua entre la U-Net y los modelos fundacionales. En el Perú, sin datos peruanos, Prithvi fue el modelo que menos perdió (0.080) y la U-Net el que más (0.257).
2. El cambio de dominio se concentra en el suelo seco. La adaptación sin datos etiquetados del Perú para el entrenamiento mejoró a la U-Net (+0.222) y a TerraMind (+0.082) en la prueba de 2023, sin alcanzar a los modelos entrenados en el Perú; la U-Net cerró el 88 % de la brecha.
3. Con datos etiquetados del Perú, los tres modelos quedan próximos (0.815 a 0.828 en la prueba de 2023), y partir de los pesos de Sen1Floods11 no cambia el resultado.
4. Los modelos son sobreconfiados. El escalado de temperatura ajustado en el dominio de origen y los ensambles redujeron el ECE en todas las configuraciones congeladas.
5. Ajustar los hiperparámetros en el dominio de origen no resuelve el cambio de dominio, y las variables diseñadas a mano no aportan cuando hay etiquetas del dominio.

Lo que permanece indeterminado.

- Si el sistema cumple sus requisitos y el tiempo de 15 minutos por tesela: no se ha medido.
- Si la adaptación ayuda fuera del evento de 2023. Frente a la referencia de 2017 empeora, pero esa referencia mide sobre todo el agua evidente; falta una referencia independiente.
- Si TerraMind pierde menos que la U-Net en el Perú: el intervalo excluye el cero por muy poco y no incorpora la variación entre semillas.
- Si Prithvi puede mejorar con adaptación: ningún método probado lo logró en la validación.
- Cuánto ganarían los modelos entrenados en el Perú con una búsqueda propia de hiperparámetros.

9.2 Riesgos y plan de mitigación

La Tabla 17 ordena los riesgos por prioridad.

Tabla 17

Riesgos y plan de mitigación

Riesgo	Impacto	Mitigación	Evidencia y responsable
El tiempo por tesela supera los 15 minutos por la descarga, que depende de un servicio externo	Alto: la tercera hipótesis no se cumpliría	Medir según el protocolo e informar todos los tiempos y el máximo; un resultado adverso se informa como tal	En corridas de desarrollo, la descarga tomó de 102 a 361 s. Autores
No hay asesor asignado y el plan debe aprobarse en la semana 14	Alto: afecta a la nota del curso y al trámite	Gestionar la asignación ante la Unidad de Posgrado en la semana 10	Sílabo del curso. Autores
El título aprobado ya no describe el trabajo	Medio	Consultar si el cambio de título exige una solicitud formal	Reglas de redacción del proyecto. Autores
La adaptación pierde agua tenue en otros eventos	Medio: limita la utilidad del modelo adaptado	El sistema usa por defecto la U-Net entrenada en el Perú y ofrece el modelo adaptado como capa de comparación; se informa el *recall* por condición	Prueba de 2017. Autores
Las etiquetas contienen errores	Medio: sesga las métricas	Análisis de sensibilidad sin los recortes dudosos; IoU tolerante al borde; cuantificar el optimismo de 2017	Lista de recortes dudosos. Autores
La incertidumbre no señala el agua tenue ni los cuerpos pequeños	Medio: el usuario podría confiar de más en el mapa	Declararlo en la aplicación y en la tesis	Análisis de calibración por condición. Autores
Los resultados no se reproducen bit a bit en GPU	Bajo	Puntos de control con suma de verificación; conclusiones basadas en intervalos	Registro de corridas. Autores
Uso indebido de los mapas en una emergencia	Bajo: riesgo ético	Presentar el sistema como prototipo de investigación	Sección de ética. Autores

Nota. Elaboración propia.

9.3 Trabajo futuro para el siguiente *sprint*

La Tabla 18 lista el trabajo de las semanas 10 a 12. Los dos autores son responsables de todas las actividades.

Tabla 18
Trabajo del siguiente sprint

Actividad	Entregable	Criterio de aceptación	Fecha
Decidir las reglas pendientes del sistema y etiquetar su versión	Versión etiquetada en el repositorio	Árbol de trabajo limpio; el programa de medición acepta ejecutarse	Semana 10 (20 de noviembre)
Medir los requisitos RF1 a RF7	Lista de verificación con la evidencia de cada requisito	Cada requisito tiene resultado (aprobado o no aprobado) y archivo de evidencia	Semana 10 (20 de noviembre)
Medir el tiempo por tesela	Tabla de 18 tiempos (seis teselas, tres repeticiones)	Se informan todos los tiempos, la mediana por tesela y el máximo	Semana 11 (27 de noviembre)
Cuantificar el optimismo de las etiquetas de 2017	Proporción del área de EMS descartada y su efecto posible en el IoU	Cifra con archivo fuente, añadida a la tesis	Semana 11 (27 de noviembre)
Redactar la sección del sistema y la contrastación de la tercera hipótesis	Capítulo III de la tesis completo	Compila; cada cifra tiene su fuente	Semana 12 (4 de diciembre)
Medir la importancia de bandas en TerraMind y Prithvi, con tres semillas	Tabla de importancia de los tres modelos	Mismo programa que la U-Net; solo validación	Semana 12 (4 de diciembre)
Gestionar la asignación del asesor	Solicitud presentada	Constancia de presentación	Semana 10 (20 de noviembre)

Nota. Elaboración propia. Queda fuera del sprint, sujeta a una decisión de costo, la búsqueda de la tasa de aprendizaje de los modelos entrenados en el Perú.

REFERENCIAS

Banerjee, A., y Daou, D. (2026). *Explainable flood segmentation on Sentinel-1 SAR imagery: A comparative study of CNN and Transformer architectures.* Descargado de https://arxiv.org/abs/2606.16302

Ben-David, S., Blitzer, J., Crammer, K., Kulesza, A., Pereira, F., y Vaughan, J. W. (2010). A theory of learning from different domains. *Machine Learning*, *79*(1–2), 151–175. doi: 10.1007/s10994-009-5152-4

Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., … Liang, P. (2021). *On the Opportunities and Risks of Foundation Models.* Descargado de https://arxiv.org/abs/2108.07258

Bonafilia, D., Tellman, B., Anderson, T., y Issenberg, E. (2020, junio). Sen1Floods11: a georeferenced dataset to train and test deep learning flood algorithms for Sentinel-1. En *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)* (pp. 835–845). IEEE. Descargado de http://dx.doi.org/10.1109/CVPRW50498.2020.00113 doi: 10.1109/cvprw50498.2020.00113

Breña-Aliaga, J. C., y Cruz-Machacuay, J. (2026). Estimación de umbrales y dinámica de inundaciones integrando Random Forest, el índice SDWI de Sentinel-1, el modelo HAND y datos SAR en la cuenca del río Tumbes. *Ingeniería del Agua*, *30*(3), 211–228. Descargado de https://doi.org/10.4995/ia.25917 doi: 10.4995/ia.25917

Chen, W., Wang, C., Zhao, Z., y Li, X. (2026, agosto). Improving Cross-Event Generalization for SAR-Based Coastal Inundation Mapping via Test-Time Domain Adaptation. *Journal of Geophysical Research: Machine Learning and Computation*, *3*(4), e2025JH001145. Descargado de http://dx.doi.org/10.1029/2025JH001145 doi: 10.1029/2025jh001145

Comisión Multisectorial encargada del Estudio Nacional del Fenómeno “El Niño” (ENFEN). (2023, mayo). *Informe Técnico ENFEN, Año 9, N° 7, al 09 de mayo de 2023* (Inf. Téc.). Lima: ENFEN. Descargado de https://repositorio.imarpe.gob.pe/bitstream/20.500.12958/8543/1/Informe%20Tecnico%20ENFEN%20MAYO%2011-05-2023.pdf

Copernicus. (s.f.). *S2 Products.* SentiWiki. Descargado 16 de octubre de 2026, de https://sentiwiki.copernicus.eu/web/s2-products

Copernicus Emergency Management Service. (2017). *EMSR199: Floods in Peru.* Copernicus Emergency Management Service, Rapid Mapping. Descargado de https://mapping.emergency.copernicus.eu/activations/EMSR199/

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., … Houlsby, N. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. En *International Conference on Learning Representations (ICLR).* Descargado de https://openreview.net/forum?id=YicbFdNTTy

Efron, B., y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Springer US. doi: 10.1007/978-1-4899-4541-9

European Space Agency. (2015, julio). Sentinel-2 User Handbook (Issue 1, Revision 2 ed.) [Ma-

nual de software informático]. Descargado de https://sentinels.copernicus.eu/documents/247904/685211/Sentinel-2_User_Handbook

Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., y Zisserman, A. (2010). The PASCAL Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision*, *88*(2), 303–338. doi: 10.1007/s11263-009-0275-4

French, A., Mechler, R., Arestegui, M., MacClune, K., y Cisneros, A. (2020, agosto). Root causes of recurrent catastrophe: The political ecology of El Niño-related disasters in Peru. *International Journal of Disaster Risk Reduction*, *47*, 101539. Descargado de http://dx.doi.org/10.1016/j.ijdrr.2020.101539 doi: 10.1016/j.ijdrr.2020.101539

Gomes, C., Blumenstiel, B., De Sousa Almeida, J. L., De Oliveira, P. H., Fraccaro, P., Escofet, F. M., … Zadrozny, B. (2025). TerraTorch: The Geospatial Foundation Models Toolkit. En *IGARSS 2025 – 2025 IEEE International Geoscience and Remote Sensing Symposium* (pp. 6364–6368). IEEE. doi: 10.1109/IGARSS55030.2025.11243570

Gonzalez, R. C., y Woods, R. E. (2018). *Digital Image Processing* (4th ed.). New York: Pearson.

Guo, C., Pleiss, G., Sun, Y., y Weinberger, K. Q. (2017). On Calibration of Modern Neural Networks. En *Proceedings of the 34th International Conference on Machine Learning* (Vol. 70, pp. 1321–1330). PMLR. Descargado de https://proceedings.mlr.press/v70/guo17a.html

He, K., Zhang, X., Ren, S., y Sun, J. (2016). Deep Residual Learning for Image Recognition. En *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 770–778). IEEE. doi: 10.1109/CVPR.2016.90

Hendrycks, D., y Gimpel, K. (2017). A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks. En *International Conference on Learning Representations (ICLR).* Descargado de https://openreview.net/forum?id=Hkg4TI9xl

Instituto Nacional de Defensa Civil. (2017, diciembre). *Compendio Estadístico del INDECI 2017: Gestión Reactiva* (Inf. Téc.). Lima: Instituto Nacional de Defensa Civil (INDECI), Dirección de Políticas, Planes y Evaluación. Descargado de https://cdn.www.gob.pe/uploads/document/file/1048401/20180227171454120200726-15599-1ptpifw.pdf

Instituto Nacional de Defensa Civil. (2024, octubre). *Compendio Estadístico de la Gestión Reactiva al primer semestre 2024* (Inf. Téc.). Lima: Instituto Nacional de Defensa Civil (INDECI), Dirección de Políticas, Planes y Evaluación. Descargado de https://cdn.www.gob.pe/uploads/document/file/7175987/6151912-compendio-estadistico-2024.pdf

Jakubik, J., Yang, F., Blumenstiel, B., Scheurer, E., Sedona, R., Maurogiovanni, S., … Longépé, N. (2025, octubre). Terramind: Large-Scale Generative Multimodality for Earth Observation. En *2025 IEEE/CVF International Conference on Computer Vision (ICCV)* (pp. 7383–7394). IEEE. Descargado de http://dx.doi.org/10.1109/iccv51701.2025.00693 doi: 10.1109/iccv51701.2025.00693

Kolluru, V., Shinde, R., Marouane, A., Helbling, C., Shah, D., Drew, O., … Ramachandran, R. (2026). *Land cover and flood type govern the detection limits of satellite-based flood*

mapping across diverse global flood events. Descargado de https://arxiv.org/abs/2606.07780

Lakshminarayanan, B., Pritzel, A., y Blundell, C. (2017). Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles. En *Advances in Neural Information Processing Systems* (Vol. 30). Descargado de https://papers.nips.cc/paper/2017/hash/9ef2ed4b7fd2c810847ffa5fa85bce38-Abstract.html

Li, W., Lee, H., Wang, S., Hsu, C.-Y., y Arundel, S. T. (2023, noviembre). Assessment of a new GeoAI foundation model for flood inundation mapping. En *Proceedings of the 6th ACM SIGSPATIAL International Workshop on AI for Geographic Knowledge Discovery* (pp. 102–109). ACM. Descargado de http://dx.doi.org/10.1145/3615886.3627747 doi: 10.1145/3615886.3627747

Li, Y., Wang, N., Shi, J., Hou, X., y Liu, J. (2018). Adaptive Batch Normalization for practical domain adaptation. *Pattern Recognition*, *80*, 109–117. doi: 10.1016/j.patcog.2018.03.005

Long, J., Shelhamer, E., y Darrell, T. (2015). Fully convolutional networks for semantic segmentation. En *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 3431–3440). IEEE. doi: 10.1109/CVPR.2015.7298965

Marsocci, V., Jia, Y., Le Bellier, G., Kerekes, D., Zeng, L., Hafner, S., … Nascetti, A. (2026, febrero). PANGAEA: Assessing Geospatial Foundation Models Capabilities through a Global and Inclusive Benchmark. *IEEE Geoscience and Remote Sensing Magazine*, *14*(1), 245–285. Descargado de http://dx.doi.org/10.1109/mgrs.2025.3628194 doi: 10.1109/mgrs.2025.3628194

McFeeters, S. K. (1996). The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features. *International Journal of Remote Sensing*, *17*(7), 1425–1432. doi: 10.1080/01431169608948714

Milletari, F., Navab, N., y Ahmadi, S.-A. (2016). V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation. En *2016 Fourth International Conference on 3D Vision (3DV)* (pp. 565–571). IEEE. doi: 10.1109/3DV.2016.79

Ovadia, Y., Fertig, E., Ren, J., Nado, Z., Sculley, D., Nowozin, S., … Snoek, J. (2019). Can you trust your model's uncertainty? Evaluating predictive uncertainty under dataset shift. En *Advances in Neural Information Processing Systems* (Vol. 32). Descargado de https://papers.nips.cc/paper/2019/hash/8558cb408c1d76621371888657d2eb1d-Abstract.html

Ronneberger, O., Fischer, P., y Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. En N. Navab, J. Hornegger, W. M. Wells, y A. F. Frangi (Eds.), *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015* (pp. 234–241). Cham: Springer International Publishing. doi: 10.1007/978-3-319-24574-4_28

Shen, M., Zhang, F., y Wu, C. Y. (2022). Flood Inundation Extraction Based on Decision-Level Data Fusion: A Case in Peru. *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, *X-3/W1-2022*, 133–140. Descargado de https://doi.org/10.5194/isprs-annals-X-3-W1-2022-133-2022 doi: 10.5194/isprs-annals-X-3-W1-2022-133-2022

Szwarcman, D., Roy, S., Fraccaro, P., Þorsteinn Elí Gíslason, Blumenstiel, B., Ghosal, R., … Bernabe Moreno, J. (2024). *Prithvi-eo-2.0: A Versatile Multi-Temporal Foundation Model for Earth Observation Applications.* Descargado de https://arxiv.org/abs/2412.02732

Tarvainen, A., y Valpola, H. (2017). Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. En *Advances in Neural Information Processing Systems* (Vol. 30). Descargado de https://papers.nips.cc/paper/2017/hash/68053af2923e00204c3ca7c6a3150cf7-Abstract.html

United Nations Satellite Centre (UNOSAT). (2023a). *Satellite detected water extents over Lambayeque and Piura Province Provinces, Peru as of 1 April 2023.* Humanitarian Data Exchange (HDX), data set. Descargado de https://data.humdata.org/dataset/69d4820c-c1bd-4938-9409-877e06c284dc

United Nations Satellite Centre (UNOSAT). (2023b). *Satellite detected water extents over Lambayeque and Piura Province Provinces, Peru as of 22 March 2023.* Humanitarian Data Exchange (HDX), data set. Descargado de https://data.humdata.org/dataset/3e1cf0c7-5e87-43e6-b04f-2d1c3f982061

Wang, J., Zheng, Z., Ma, A., Lu, X., y Zhong, Y. (2021). LoveDA: A Remote Sensing Land-Cover Dataset for Domain Adaptive Semantic Segmentation. En *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks* (Vol. 1). Descargado de https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/hash/4e732ced3463d06de0ca9a15b6153677-Abstract-round2.html

Xu, H. (2006). Modification of normalised difference water index (NDWI) to enhance open water features in remotely sensed imagery. *International Journal of Remote Sensing*, *27*(14), 3025–3033. doi: 10.1080/01431160600589179

Yang, Y., y Soatto, S. (2020). FDA: Fourier Domain Adaptation for Semantic Segmentation. En *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 4084–4094). IEEE. doi: 10.1109/CVPR42600.2020.00414

Zou, Y., Yu, Z., Vijaya Kumar, B. V. K., y Wang, J. (2018). Unsupervised Domain Adaptation for Semantic Segmentation via Class-Balanced Self-training. En V. Ferrari, M. Hebert, C. Sminchisescu, y Y. Weiss (Eds.), *Computer Vision – ECCV 2018* (pp. 297–313). Cham: Springer International Publishing. doi: 10.1007/978-3-030-01219-9_18

ANEXOS

Anexo A. Matriz de consistencia

Problema	Objetivo	Hipótesis	Variable	Indicador medible
¿De qué manera se puede desarrollar un sistema de análisis satelital de inundaciones para el Perú, basado en modelos de segmentación profunda, que genere mapas de la extensión del agua y de su incertidumbre a partir de imágenes Sentinel-2, aun cuando no se dispone de datos etiquetados del Perú para entrenar los modelos?	**Objetivo general.** Desarrollar un sistema de análisis satelital de inundaciones para el Perú, basado en modelos de segmentación profunda, que genere mapas de la extensión del agua y de su incertidumbre a partir de imágenes Sentinel-2.	**Hipótesis general.** Los modelos fundacionales geoespaciales pierden menos desempeño que la U-Net al pasar de Sen1Floods11 al Perú; la adaptación de dominio y la calibración mejoran en parte la confiabilidad de los mapas, y el sistema cumple sus requisitos en un tiempo adecuado para la respuesta después de un evento.	**Independiente:** modelo de segmentación, estrategia de entrenamiento o adaptación y configuración del sistema. **Dependiente:** calidad del mapeo de inundaciones.	IoU de agua; caída de IoU de Sen1Floods11 al Perú; ECE; AUROC; requisitos cumplidos (%); tiempo por escena (min).
PE1. ¿Qué modelo de segmentación y qué esquema de entrenamiento ofrecen el mejor desempeño en Sen1Floods11 y en el Perú?	**OE1.** Comparar el IoU de agua de TerraMind v1-B, Prithvi-EO-2.0 300M y U-Net en Sen1Floods11 y en los eventos peruanos de 2023 y 2017, con tres esquemas de entrenamiento, para seleccionar el modelo del sistema.	**HE1.** En Sen1Floods11 no se detecta una diferencia significativa de IoU de agua entre los modelos fundacionales y la U-Net. En el Perú, la caída de IoU de los modelos fundacionales es menor que la de la U-Net.	**Independiente:** arquitectura (TerraMind, Prithvi, U-Net) y esquema de entrenamiento (Sen1Floods11; Perú; Sen1Floods11 y ajuste fino en el Perú). **Dependiente:** exactitud de la segmentación y generalización al Perú.	IoU de agua; diferencia pareada de IoU con intervalo de confianza al 95 %; caída de IoU de Sen1Floods11 al Perú.
PE2. ¿En qué medida la adaptación de dominio sin datos etiquetados del Perú reduce la pérdida de desempeño de los modelos, y está calibrada la incertidumbre que mostrará el sistema?	**OE2.** Determinar en qué medida la adaptación de dominio no supervisada y la calibración de la incertidumbre mejoran la confiabilidad de los mapas en el Perú, e identificar las condiciones en las que se concentran los errores.	**HE2.** Los errores se concentran en pocas condiciones (bordes de nubes, vegetación inundada, terreno desértico o costero). La adaptación aumenta el IoU de agua sin llegar al modelo entrenado en el Perú. El escalado de temperatura y los ensambles reducen el ECE, y la incertidumbre permite detectar errores.	**Independiente:** método de adaptación (ninguno, igualación de histogramas, FDA, AdaBN) y tratamiento de la incertidumbre (sin calibrar, escalado de temperatura, ensamble). **Dependiente:** generalización al Perú, calibración y detección de errores.	Diferencia de IoU entre el modelo adaptado y el modelo sin adaptar (intervalo al 95 %); proporción de errores por condición; ECE (%); AUROC de detección de errores (mayor que 0.5).
PE3. ¿En qué medida el sistema implementado cumple los requisitos funcionales y el tiempo de procesamiento necesarios para usarlo después de un evento de inundación?	**OE3.** Implementar el sistema como una aplicación web y evaluar si cumple los requisitos funcionales y el tiempo de procesamiento por escena Sentinel-2.	**HE3.** El sistema cumple el 100 % de los requisitos funcionales RF1 a RF7 y procesa una escena Sentinel-2 completa en 15 minutos o menos, incluida la descarga.	**Independiente:** configuración del sistema (modelo seleccionado, flujo de obtención y procesamiento de imágenes). **Dependiente:** desempeño del sistema.	Requisitos funcionales cumplidos (%); tiempo de procesamiento por escena (min).

Nota. Elaboración propia. IoU: intersección sobre la unión; ECE: error de calibración esperado; AUROC: área bajo la curva ROC.

Anexo B. Cronograma detallado

Actividad	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Plan de investigación e hipótesis	■	■												
Reproducción en Sen1Floods11		■	■											
Construcción del conjunto peruano		■	■											
Entrenamiento en el Perú y análisis de errores		■	■											
Adaptación de dominio y calibración			■											
Congelamiento y evaluación única en prueba			■											
Redacción de los capítulos I a III			■	■										
Desarrollo del sistema				■										
Análisis de datos, variables e hiperparámetros			■	■	■	■								
Informe parcial y defensa intermedia							■							
Medición formal del sistema								▒	▒					
Análisis complementarios								▒	▒	▒				
Redacción del sistema y del capítulo IV									▒	▒	▒			
Aprobación del plan de tesis												▒		
Introducción, resumen, anexos y revisión final											▒	▒	▒	
Borrador integral y defensa final														▒

Nota. Elaboración propia. Columnas: semanas del curso (la semana 9 corresponde a la del 9 al 13 de noviembre de 2026). Gris oscuro: ejecutado; gris claro: planificado.

Anexo C. Diccionario de datos

Variable	Tipo y unidad	Descripción
Imagen del recorte	13 bandas, entero	Números digitales del nivel 1C (reflectancia en el techo de la atmósfera × 10 000), 512 × 512 píxeles a 10 m. Bandas: B01, B02, B03, B04, B05, B06, B07, B08, B8A, B09, B10, B11 y B12
B02, B03, B04	Visible	Azul, verde y rojo; resolución original de 10 m
B05, B06, B07, B8A	Borde rojo e infrarrojo cercano estrecho	Resolución original de 20 m
B08	Infrarrojo cercano	Resolución original de 10 m; con B03 forma el NDWI
B11, B12	Infrarrojo de onda corta	Resolución original de 20 m; con B03, B11 forma el MNDWI
B01, B09, B10	Atmosféricas	Aerosoles, vapor de agua y cirros; resolución original de 60 m
Etiqueta	Entero por píxel	1: agua. 0: no agua. −1: ignorado (fuera del área analizada, nube gruesa o sin datos)
Partición	Categoría	Entrenamiento, validación, prueba o *buffer*; se asigna por ubicación
Ubicación	Celda de cuadrícula	Celda de 5 120 m en UTM zona 17 sur (EPSG:32717)
Fecha	Fecha	2023-03-22, 2023-04-01 o 2017-04-07
Sumas de verificación	SHA-256	Una por imagen y una por etiqueta, en el manifiesto
Estratos de análisis	Categoría por píxel	Distancia al borde del agua, distancia a nubes gruesas y cobertura del suelo (ESA WorldCover)

Nota. Elaboración propia a partir de la ficha de datos del conjunto peruano.

Anexo D. Registro de corridas

run_id	commit / datos	seed / split	métrica	artefacto
`s1f11_src_unet`	`8a8fee4` / Sen1Floods11 v1.1	0, 1, 2 / validación de origen	IoU de agua 0.832 ± 0.001	`outputs/s1f11_src_unet/`
`s1f11_src_terramind_lr5e-5`	`8a8fee4` / Sen1Floods11 v1.1	0, 1, 2 / validación de origen	IoU de agua 0.835 ± 0.001	`outputs/s1f11_src_terramind_lr5e-5/`
`s1f11_src_prithvi`	`e8001a4` / Sen1Floods11 v1.1	0, 1, 2 / validación de origen	IoU de agua 0.832 ± 0.005	`outputs/s1f11_src_prithvi/`
`runs_cloud/unet`	`55c5e04` o `45270f1` / Perú v1	0, 1, 2 / validación peruana	IoU de agua 0.941 ± 0.002	`outputs/runs_cloud/unet/`
`runs_cloud/terramind_v1_base`	`55c5e04` o `45270f1` / Perú v1	0, 1, 2 / validación peruana	IoU de agua 0.927 ± 0.002	`outputs/runs_cloud/terramind_v1_base/`
`runs_cloud/prithvi_eo_v2_300`	`55c5e04` o `45270f1` / Perú v1	0, 1, 2 / validación peruana	IoU de agua 0.922 ± 0.001	`outputs/runs_cloud/prithvi_eo_v2_300/`
`runs_cloud_s1f11_ft`	`0edf781` / Perú v1	0, 1, 2 / validación peruana	IoU de agua 0.938, 0.928 y 0.924 (tres modelos)	`outputs/runs_cloud_s1f11_ft/`
`s1f11_trhm_unet`	`e8001a4` / Sen1Floods11 e imágenes peruanas sin etiquetas	0, 1, 2 / validación peruana	IoU de agua 0.912 ± 0.003	`outputs/s1f11_trhm_unet/`
`s1f11_trfda_unet`	`e8001a4` / ídem	0, 1, 2 / validación peruana	IoU de agua 0.615 ± 0.112	`outputs/s1f11_trfda_unet/`
`s1f11_trfda_terramind_v1_base`	`e8001a4` / ídem	0, 1, 2 / validación peruana	IoU de agua 0.836 ± 0.001	`outputs/s1f11_trfda_terramind_v1_base/`
Autoentrenamiento	`e8a5841` / ídem	0, 1, 2 / validación peruana	IoU de agua 0.818 ± 0.110 (U-Net); 0.484 ± 0.027 (TerraMind)	`outputs/phaseD/self_train/`
Evaluación congelada, 2023	`f1f61d6` / Perú v1	33 corridas / prueba de 2023	Tabla 14	`outputs/phaseD/test/peru-test_groups.csv`
Evaluación congelada, 2017	`f1f61d6` / Perú v1	33 corridas / prueba de 2017	Sección 8.2	`outputs/phaseD/test/peru-2017-test_groups.csv`
Calibración en prueba	`f2ad639` / Perú v1	Configuraciones congeladas / pruebas	ECE y AUROC	`outputs/phaseD/test/calibration.md`
Ajuste fino y Sen1Floods11, prueba	`d42c861` / Perú v1 y Sen1Floods11	9 corridas / pruebas	Sección 8.2	`outputs/logits_test/s1f11_ft/`

Nota. Elaboración propia. Extracto del registro completo, `docs/EXPERIMENT_LOG.md`. Las carpetas `outputs/` no se versionan; los 36 puntos de control congelados se conservan localmente y el resto está archivado.

Anexo E. Evidencia de ejecución

- **Repositorio.** `https://github.com/gersongams/peru-flood-segmentation`. Las ramas `avance-sem4-eda`, `avance-sem5-feature-engineering`, `avance-sem6-sprint`, `avance-matriz-consistencia` y `avance-sem8-hiperparametros` contienen los avances semanales; todas están integradas en la rama principal.
- **Cuadernos ejecutados.** `notebooks/eda.ipynb`, `notebooks/feature_engineering.ipynb`, `notebooks/baseline_variantes.ipynb` y `notebooks/optimizacion_hiperparametros.ipynb`.
- **Informes de análisis.** `docs/phaseD_dev.md` (adaptación en validación), `docs/phaseD_test.md` (evaluación única), `docs/failure_analysis_dev.md` (errores), `docs/calibration_dev.md` y `docs/uncertainty_dev.md` (calibración), `docs/domain_shift_dev.md` (cambio de dominio) y `docs/published_comparison.md` (comparación con valores publicados).
- **Pruebas automáticas.** `tests/test_target_pool.py`: 13 pruebas que verifican que la adaptación no lee etiquetas peruanas.
- **Sistema.** Registros del servidor en `outputs/system/` y comprobaciones de requisitos en `outputs/system_eval/rf/`.