Informe parcial: resumen de estudio

Sistema de análisis satelital de inundaciones basado en modelos de segmentación profunda para el mapeo de áreas inundadas en el Perú

Gerson Andre Garrido Mansilla y Renzo Elvis Cerron Tome · Proyecto de Investigación II · noviembre de 2026

La idea en 30 segundos

- **Qué hacemos.** Un sistema que toma una imagen Sentinel-2 del Perú y entrega el mapa del agua y su incertidumbre.
- **Cómo.** Tres pasos: (1) comparar tres modelos, (2) elegir uno con esa evidencia, (3) construir con él una aplicación web funcional. La comparación es el medio, no el fin.
- **Problema de fondo.** Los modelos se entrenaron con datos de otras regiones (Sen1Floods11). En la costa peruana confunden el desierto brillante con agua: eso es el cambio de dominio.
- **Estado.** Pasos 1 y 2 terminados, con las pruebas evaluadas una sola vez. Paso 3: la aplicación ya funciona con datos reales; falta su medición formal (requisitos y tiempo).

Los números que hay que saber (IoU de agua)

Qué	Valor
Sen1Floods11, prueba: U-Net / Prithvi / TerraMind	0.833 / 0.820 / 0.819 (no se distinguen)
Perú 2023, prueba, modelos de origen sin adaptar	U-Net 0.576, TerraMind 0.626, Prithvi 0.740
Perú 2023, prueba, entrenados en el Perú (cota superior)	U-Net 0.828, Prithvi 0.824, TerraMind 0.815
Perú 2023, U-Net con igualación de histogramas (sin etiquetas del Perú)	0.798; +0.222 [0.132, 0.309] sobre el origen; cierra el 88 % de la brecha
Lo que le falta frente a la U-Net entrenada en el Perú	−0.030 [−0.048, −0.013]
Perú 2017: el orden se invierte	origen 0.917–0.937; adaptados 0.831–0.887; peruanos 0.878–0.892
Caída de Sen1Floods11 al Perú	U-Net 0.257, TerraMind 0.192, Prithvi 0.080
Calibración (ECE, U-Net adaptada, prueba 2023)	1.96 % → 0.60 % con ensamble y temperatura
Datos peruanos de 2023	1 291 recortes: 753 / 174 / 172 y 192 de *buffer*
Costo de GPU	34.11 USD

PARTE I. PLAN DE TESIS

Datos generales

Título: el de arriba. Asesor: por asignar. Programa: Maestría en Ciencias con mención en Inteligencia Artificial (FIIS-UNI). Lugar: Lima; zona de estudio: Lambayeque y Piura. Inicio: septiembre de 2026; borrador integral: enero de 2027.

CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA

1.1 Diagnóstico

- **Magnitud.** Niño Costero 2017: 285 453 damnificados, 138 fallecidos, US$ 3.1 mil millones. Ciclón Yaku 2023: 107 780 damnificados y 44 fallecidos en ocho departamentos (INDECI).
- **Síntomas.** Los mapas de agua los hacen especialistas, después del evento y como productos preliminares (UNOSAT: 985.9 km² al 22 de marzo de 2023). Los modelos automáticos, sin ajuste, marcan desierto como agua.
- **Causas.** No hay un conjunto óptico peruano etiquetado; el suelo seco peruano es mucho más brillante (cambio de dominio); la confianza de los modelos no siempre coincide con su acierto.
- **Consecuencias.** Un mapa que sobreestima el agua y sin incertidumbre confiable sirve poco para estimar la extensión tras el paso del satélite.

1.1.1 Identificación y descripción del problema de estudio

Cómo integrar y evaluar modelos de segmentación en un sistema que mapee el agua con Sentinel-2 en el Perú, sabiendo que pierden desempeño y calibración fuera de sus datos. Objeto: sistema con TerraMind v1-B, Prithvi-EO-2.0 300M y U-Net. Lugar: Lambayeque y Piura (2023), bajo Piura y Sechura (2017). Fechas: 22 de marzo y 1 de abril de 2023; 7 de abril de 2017.

1.1.2 Antecedentes bibliográficos

- En Sen1Floods11, la U-Net iguala o supera a los modelos fundacionales (Li et al. 2023: 84.03 frente a 81.98 %); en Bolivia, fuera del entrenamiento, gana Prithvi (76.62 frente a 70.57 %).
- Prithvi-EO-2.0 sin adaptar en 19 eventos nuevos: IoU 0.46, precisión 0.49, *recall* 0.90 (Kolluru et al. 2026): sobredetecta.
- Adaptación: LoveDA fija el protocolo de tres niveles (sin adaptar, adaptado, cota superior) que seguimos.
- En el Perú: Shen et al. 2022 (Piura 2017, IoU 0.69) y Breña-Aliaga 2026 (Tumbes, radar, 69.02 %).
- **Brecha.** No se identificaron estudios que evalúen y adapten modelos fundacionales con Sentinel-2 en la costa árida peruana sin etiquetas locales, ni que midan su calibración. La búsqueda no es sistemática: no decimos «no existe».

1.1.3 Formulación del problema

General. ¿De qué manera se puede desarrollar un sistema de análisis satelital de inundaciones para el Perú que genere mapas del agua y de su incertidumbre con Sentinel-2, aun sin datos etiquetados del Perú para entrenar? **Específicos.** (1) ¿Qué modelo y qué esquema de entrenamiento rinden mejor? (2) ¿Cuánto ayuda la adaptación sin etiquetas del Perú, y está calibrada la incertidumbre? (3) ¿Cumple el sistema sus requisitos y su tiempo de procesamiento?

1.2 Justificación y alcances

1.2.1 Justificación

Teórica: ver si el preentrenamiento geoespacial reduce la pérdida al cambiar de región. **Práctica:** ante una inundación nueva hay imágenes pero no etiquetas; el sistema daría el mapa poco después del paso del satélite. **Metodológica:** conjunto peruano sin etiquetado manual, particiones espaciales, tres semillas, prueba única e intervalos de confianza.

1.2.2 Alcances

Cubre: agua y no agua en Sentinel-2 L1C, tres modelos, tres esquemas, adaptación no supervisada y una aplicación web con evaluación técnica. **No cubre:** pronóstico, radar, mapas de riesgo ni pruebas con usuarios. **Ojo:** el modelo detecta agua visible, incluida la permanente; «área inundada» solo se usa al restar una imagen previa al evento. Etiquetas con errores; nubes excluidas; tres semillas; prototipo.

CAPÍTULO II. OBJETIVOS

2.1 Objetivo general

Desarrollar un sistema de análisis satelital de inundaciones para el Perú, basado en modelos de segmentación profunda, que genere mapas de la extensión del agua y de su incertidumbre a partir de imágenes Sentinel-2.

2.2 Objetivos específicos

- **OE1** Comparar los tres modelos en Sen1Floods11 y en el Perú, con tres esquemas de entrenamiento, para seleccionar el modelo del sistema. Estado: cumplido.
- **OE2** Determinar cuánto mejoran la adaptación y la calibración la confiabilidad de los mapas, e identificar dónde se concentran los errores. Estado: cumplido.
- **OE3** Implementar el sistema como aplicación web y evaluar requisitos y tiempo por escena. Estado: implementado; medición pendiente.

CAPÍTULO III. MARCO TEÓRICO

3.1 Bases teóricas

- **Sentinel-2:** 13 bandas, 10 a 60 m, revisita de cinco días; nivel 1C = reflectancia en el techo de la atmósfera. Índices NDWI (B3, B8) y MNDWI (B3, B11): el agua refleja poco en el infrarrojo.
- **U-Net:** codificador y decodificador con conexiones directas; aquí con ResNet-34 y pérdida de Dice.
- **Modelos fundacionales:** *Transformers* preentrenados con muchísimas imágenes satelitales (Prithvi con HLS de 30 m; TerraMind multimodal). Procesan parches de 16 × 16 píxeles: pierden detalle en los bordes.
- **Adaptación sin etiquetas:** igualación de histogramas y FDA (alinean la entrada), AdaBN (recalcula estadísticas de normalización), autoentrenamiento (pseudoetiquetas).
- **Métricas:** IoU = TP / (TP + FP + FN). ECE: diferencia entre confianza y acierto. AUROC: si la incertidumbre señala los errores (0.5 = azar). *Bootstrap* pareado por recortes para los intervalos.

3.2 Definición de términos

Recorte: 512 × 512 px (5.12 km). Tesela: 110 × 110 km. Modelo de origen: entrenado solo en Sen1Floods11. Cota superior: entrenado con etiquetas del Perú. Brecha cerrada: cuánto de la distancia entre ambos recupera un método. Configuración congelada: lo que se fijó antes de la prueba. *Buffer*: recortes sin uso que separan entrenamiento de evaluación.

3.3 Hipótesis y variables

- **HE1** En Sen1Floods11 no se detecta diferencia entre modelos; en el Perú los fundacionales caen menos que la U-Net.
- **HE2** Los errores se concentran en pocas condiciones; la adaptación mejora sin llegar al modelo peruano; temperatura y ensambles reducen el ECE; la incertidumbre detecta errores.
- **HE3** El sistema cumple RF1 a RF7 y procesa una escena en 15 minutos o menos.
- Fijadas antes de los resultados (11, 14 y 16 de octubre de 2026) y no reformuladas.
- **Variables.** Independiente: modelo, esquema de entrenamiento o adaptación, tratamiento de la incertidumbre, configuración del sistema. Dependiente: calidad del mapeo (IoU, caída de IoU, ECE, AUROC, requisitos y tiempo).

CAPÍTULO IV. METODOLOGÍA

4.1 Tipo

Aplicada, de desarrollo tecnológico: entrega un sistema.

4.2 Nivel

Explicativo: se manipula el modelo y el método y se mide el efecto. Las explicaciones del porqué son interpretación, no causalidad demostrada.

4.3 Métodos de trabajo

Comparar, elegir, construir. Experimentos controlados con el protocolo de tres niveles; sistema desarrollado de forma iterativa frente a requisitos fijados antes.

4.4 Población y muestra

Población: imágenes Sentinel-2 L1C de inundaciones. Muestra no probabilística: Sen1Floods11 (252 / 89 / 90, particiones oficiales) y conjunto peruano (1 291 recortes de 2023; 204 de 2017, de los que 101 forman la prueba principal). Unidad: el recorte.

4.5 Tipo de diseño

Experimental, con comparaciones pareadas sobre los mismos recortes; todo lo demás fijo. Para el sistema: evaluación técnica frente a requisitos previos.

4.6 Recolección de datos

Datos secundarios y públicos: Copernicus Data Space, UNOSAT, Copernicus EMS. Etiquetas por reglas fijas, sin etiquetado manual. Control: sumas SHA-256, revisión con MNDWI, bloqueo de recortes de evaluación.

4.7 Análisis y procesamiento

IoU de agua (principal), precisión, *recall*, ECE, AUROC. Diferencias pareadas con IC 95 % (2 000 réplicas). Sin fugas: bloques espaciales, selección solo en validación, prueba una sola vez.

4.8 Etapas

Diagnóstico → diseño → implementación → evaluación → desarrollo del sistema → cierre.

CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS

5.1 Cronograma

Hecho (semanas 3 a 9): plan, reproducción, conjunto peruano, entrenamiento, adaptación, prueba única (16 de octubre), capítulos I a III, sistema, cuadernos. Falta: medir el sistema (semanas 10–11), análisis complementarios, capítulo IV, plan aprobado (semana 14), borrador integral (semana 16).

5.2 Presupuesto

GPU alquilada (RTX 4090, 0.89 USD/h): 34.11 USD consumidos de 40.00 cargados. Datos y *software*: 0. Computador propio.

5.3 Financiamiento

Recursos propios (35.00 USD) más un crédito de 5.00 USD del proveedor. Sin financiamiento institucional.

PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL

6. Datos y material de estudio

6.1 Origen, condiciones de uso y trazabilidad

Sen1Floods11 (público); imágenes de Copernicus (libres); mapas de UNOSAT (CC BY-SA, preliminares) y de Copernicus EMS (sobre radar, una o dos semanas antes de la imagen). Conjunto peruano construido el 12 de octubre y congelado el 14: 2 990 archivos con SHA-256; reconstruido idéntico en otro computador.

6.2 Estructura, diccionario y análisis exploratorio

- 13 bandas, 512 × 512 px; etiqueta 1 agua, 0 no agua, −1 ignorado.
- **Desbalance:** agua = 4.6 % en entrenamiento y 12.4 % en validación.
- **Cambio de dominio:** el suelo seco peruano es 1.38 a 1.68 desviaciones estándar más brillante; el agua casi no cambia (0.4).
- 32 recortes (2.5 %) con etiqueta dudosa. Los detectores de nubes habituales confunden el desierto: regla propia.
- **Sesgo:** las particiones de evaluación tienen más agua que una tesela real; las etiquetas de 2017 solo incluyen lo evidente.

6.3 Ética, privacidad y seguridad

Sin datos personales (10 m de resolución). Licencias respetadas. Credenciales fuera del repositorio. Los mapas son de investigación: no se usan en una emergencia sin un especialista.

6.4 Preprocesamiento y control de fuga

Fijo para todos: quitar el desplazamiento de +1 000, normalización oficial, reglas de etiquetado. Ajustado solo con entrenamiento: pesos, y la adaptación con las 753 imágenes peruanas sin sus etiquetas. **Honestidad clave:** los métodos se ajustan sin etiquetas del Perú, pero se eligieron con la validación peruana etiquetada.

7. Protocolo experimental

7.1 Preguntas de evaluación y criterios de éxito

Seis afirmaciones (1a, 1b, 2a, 2b, 2c, 3). Criterio general: el intervalo de confianza al 95 % de la diferencia excluye el cero en la dirección prevista. Sistema: 7 de 7 requisitos y mediana de 15 minutos o menos en seis teselas con tres repeticiones.

7.2 Diseño de particiones y validación

Holdout con particiones fijas; bloques espaciales de 4 × 4 recortes con *buffer*. **¿Por qué no K-fold?** Sen1Floods11 no se vuelve a dividir (comparabilidad), el costo de GPU se multiplicaría, y el plan solo lo preveía con menos de 30 recortes con agua (hay 79 y 63). En su lugar: tres semillas y remuestreo.

7.3 Métricas y análisis estadístico

IoU de agua agregado, umbral 0.5 sin ajustar. Media ± desviación de tres semillas. Un intervalo que incluye el cero significa «no se detectó diferencia», no «son iguales».

7.4 Baseline y variantes

Mínimo: umbral de MNDWI. Sólido: U-Net de Sen1Floods11 sin adaptar. Variantes: igualación de histogramas, FDA, AdaBN, autoentrenamiento, TerraMind, Prithvi. Referencias: modelos entrenados en el Perú.

7.5 Ingeniería de atributos o componentes

Con etiquetas del Perú, las variables diseñadas no aportan (0.930 con bandas crudas). Sin ellas, los clasificadores confunden el desierto (0.71–0.74). El esquema de entrenamiento explica el 53 % de la varianza. La U-Net depende de la banda B11 (al permutarla, 0.940 → casi cero).

7.6 Optimización y presupuesto de búsqueda

Malla de la tasa de aprendizaje, semilla 0, 10 corridas, selección en validación de Sen1Floods11: U-Net 3×10^{-4}, TerraMind 5×10^{-5}, Prithvi 10^{-4}. Mejoró en el origen (TerraMind 0.817 → 0.835) pero no en el Perú. Los modelos peruanos no tuvieron barrido.

7.7 Reproducibilidad y registro

Repositorio público; cada corrida con configuración, semilla y *commit*; registro de corridas y de decisiones; versiones fijadas; configuración congelada con sumas de verificación. Límite: la GPU no reproduce bit a bit (0.833 frente a 0.816 al repetir).

8. Resultados parciales y evidencia

Corte: 12 de noviembre de 2026. Pruebas evaluadas una sola vez, el 16 de octubre.

8.1 Estado de implementación del pipeline

Datos, entrenamiento, adaptación, calibración y prueba: completos. Sistema: implementado, con seis pantallas; procesó la tesela 17MNP en ocho fechas de 2023 y una de 2017. Comprobaciones preliminares: RF1, RF3 (IoU 0.9999 entre mapa de tesela y de recortes) y RF5 (reproduce 0.828). Tiempos de desarrollo: 163 a 429 s con descarga, fuera del protocolo. **HE3 sigue pendiente.**

8.2 Comparación cuantitativa del baseline y variantes

Ver la tabla de números de la primera página. Mensajes: (1) en Sen1Floods11 no hay diferencia; (2) sin adaptar, la U-Net es la que más cae y Prithvi la que menos; (3) la igualación de histogramas lleva a la U-Net de 0.576 a 0.798; (4) con etiquetas del Perú los tres quedan juntos; (5) **resultado desfavorable:** en 2017 los modelos sin adaptar ganan.

8.3 Ablaciones y análisis de sensibilidad

La mejora de la U-Net viene de la precisión (0.848 → 0.962). El método útil depende del modelo: FDA ayuda a TerraMind y perjudica a la U-Net; AdaBN al revés. FDA en la inferencia fracasa (0.01). El autoentrenamiento empeora. Partir de Sen1Floods11 antes de entrenar en el Perú no cambia nada. Nada mejoró a Prithvi.

8.4 Sobreajuste, errores y robustez

De validación a prueba se pierden 0.10 a 0.13 en el Perú, también en los modelos con etiquetas: la prueba es más difícil, no es sobreajuste de la adaptación. Errores: el 58 a 66 % está en la franja de un píxel junto al borde del agua. Lo más difícil: agua de bajo contraste y cuerpos menores de 1 ha. Parte del error es de la etiqueta. **Costo de adaptar:** se pierde agua tenue (*recall* 0.13 frente a 0.85 en 2017). La incertidumbre no avisa de esos fallos.

8.5 Interpretación y amenazas a la validez

Modelo elegido para el sistema: U-Net entrenada en el Perú (0.828); la U-Net adaptada queda como capa de comparación para eventos sin etiquetas. La elección se hizo conociendo la prueba: no es una validación independiente. Hipótesis: 1a coherente; 1b parcial (solo Prithvi); 2a exploratoria; 2b se confirma en 2023 y se refuta en 2017; 2c se confirma; 3 pendiente. Amenazas: tres semillas, una región, etiquetas imperfectas, 2017 comparte zona con la validación, selección con etiquetas.

9. Conclusiones del avance y próximos pasos

9.1 Conclusiones sustentadas por evidencia

(1) La comparación cumplió su función: hay un modelo elegido. (2) Para un evento sin etiquetas hay una alternativa medida. (3) El mapa se entrega con incertidumbre y se conocen sus límites. (4) La aplicación funciona con datos reales. **Indeterminado:** si el sistema cumple los 15 minutos; si la adaptación ayuda fuera de 2023; si TerraMind cae menos que la U-Net; si Prithvi puede mejorar.

9.2 Riesgos y plan de mitigación

Tiempo por tesela mayor de 15 minutos por la descarga (se informa tal cual); no hay asesor y el plan debe aprobarse en la semana 14; el título aprobado ya no describe el trabajo; la adaptación pierde agua tenue; etiquetas con errores; resultados sin copia de respaldo completa.

9.3 Trabajo futuro para el siguiente sprint

Semana 10: etiquetar la versión del sistema, medir RF1 a RF7, gestionar el asesor. Semana 11: medir el tiempo (18 corridas) y cuantificar el optimismo de 2017. Semana 12: redactar la parte del sistema e importancia de bandas en los otros dos modelos.

REFERENCIAS Y ANEXOS

Referencias

43 fuentes en formato APA, las mismas de la tesis, cada una verificada contra su original.

Anexo A. Matriz de consistencia

Un problema, un objetivo y una hipótesis generales; tres específicos de cada uno, alineados uno a uno, con sus variables e indicadores.

Anexo B. Cronograma detallado

Diagrama de Gantt por semana del curso y lista con fecha de cada paso ejecutado.

Anexo C. Diccionario de datos

Bandas, etiqueta, partición, ubicación, fecha y sumas de verificación.

Anexo D. Registro de corridas

Cada corrida con su *commit*, datos, semillas, métrica y carpeta de resultados.

Anexo E. Evidencia de ejecución

Repositorio y ramas, cuadernos, informes de análisis, 50 pruebas automáticas, verificación de los 2 990 archivos y comprobaciones del sistema.

Preguntas probables

- **¿Por qué gana la U-Net si los otros son más grandes?** Con etiquetas del Perú los tres quedan a menos de 0.014; la ventaja está en el borde del agua, donde los *Transformers* trabajan con parches de 16 px.
- **¿Entonces para qué sirven los modelos fundacionales?** Sin adaptación, Prithvi es el más robusto (cae 0.080 frente a 0.257).
- **¿Es realmente «sin etiquetas»?** El ajuste sí; la selección del método usó la validación peruana etiquetada. Lo decimos.

- **¿Por qué falla en 2017?** Esas etiquetas solo incluyen agua evidente y premian el agua tenue, que la adaptación deja de detectar.
- **¿Por qué varias semillas?** Porque una sola corrida puede engañar: el resultado cambia con la inicialización aleatoria. TerraMind de origen dio 0.764, 0.598 y 0.746 en la validación peruana según la semilla, y repetir una misma corrida de la U-Net cambió su IoU de 0.833 a 0.816. Con tres semillas se informa la media ± la desviación estándar y se ve si un método es estable (la U-Net adaptada baja la desviación de 0.022 a 0.003). Son tres, y no más, por el costo de GPU. Además, las tres semillas forman el ensamble que usa el sistema: su promedio es el mapa y su desacuerdo, la incertidumbre.
- **¿Por qué no K-fold?** Comparabilidad, costo, y el plan solo lo preveía con pocos recortes con agua.
- **¿El sistema ya está validado?** No: funciona, pero la medición de requisitos y tiempo está pendiente.
- **¿Cuál es el aporte?** Un conjunto peruano sin etiquetado manual, la medición del cambio de dominio y de la calibración en la costa árida, y un sistema que usa el modelo elegido.