MATRIZ DE CONSISTENCIA

Maestría en Ciencias con mención en Inteligencia Artificial, Universidad Nacional de Ingeniería

Tabla A. Matriz de consistencia

Título: Sistema de análisis satelital de inundaciones basado en modelos de segmentación profunda para el mapeo de áreas inundadas en el Perú					
Problema de estudio	**Problemas**	**Objetivos**	**Hipótesis**	**Variables y dimensiones**	**Diseño metodológico**
En el Perú no se cuenta con un sistema que produzca de forma automática mapas confiables de la extensión de las inundaciones con imágenes Sentinel-2. Los modelos entrenados con datos de otros países pierden desempeño cuando se aplican en la costa norte peruana, y no se sabe qué tan confiable es la incertidumbre que reportan. Para entrenar un modelo propio se necesitan etiquetas locales, que no suelen estar disponibles después de un evento.	**Problema general** ¿De qué manera se puede desarrollar un sistema de análisis satelital de inundaciones para el Perú, basado en modelos de segmentación profunda, que genere mapas de la extensión del agua y de su incertidumbre a partir de imágenes Sentinel-2, aun cuando no se dispone de datos etiquetados del Perú para entrenar los modelos?	**Objetivo general** Desarrollar un sistema de análisis satelital de inundaciones para el Perú, basado en modelos de segmentación profunda, que genere mapas de la extensión del agua y de su incertidumbre a partir de imágenes Sentinel-2.	**Hipótesis general** Los modelos fundacionales geoespaciales pierden menos desempeño que la U-Net al pasar de Sen1Floods11 al Perú. La adaptación de dominio sin datos etiquetados del Perú y la calibración de la incertidumbre mejoran en parte la confiabilidad de los mapas. El sistema que integra estos modelos cumple sus requisitos funcionales y procesa una escena en un tiempo adecuado para la respuesta después de un evento.	**Variable independiente (X)** Modelo de segmentación, estrategia de entrenamiento o adaptación y configuración del sistema. **Dimensiones:** X1. Arquitectura. X2. Esquema de entrenamiento. X3. Adaptación de dominio sin datos etiquetados del Perú. X4. Tratamiento de la incertidumbre. X5. Configuración del sistema.	**Tipo:** aplicada (desarrollo tecnológico). **Enfoque:** cuantitativo. **Nivel:** explicativo. **Método:** hipotético-deductivo; desarrollo iterativo e incremental para el sistema. **Diseño:** experimental (experimentos computacionales controlados) para los objetivos específicos 1 y 2; evaluación técnica frente a requisitos fijados de antemano para el objetivo específico 3.
	Problemas específicos PE1. ¿Qué modelo de segmentación (TerraMind, Prithvi o U-Net) y qué esquema de entrenamiento logran el mejor desempeño en Sen1Floods11 y en el Perú? PE2. ¿En qué medida la adaptación de dominio sin datos etiquetados del Perú reduce la pérdida de desempeño de los modelos en el Perú, y qué tan bien calibrada está su incertidumbre? PE3. ¿En qué medida el sistema implementado cumple los requisitos funcionales y el tiempo de procesamiento necesarios para usarlo después de una inundación?	**Objetivos específicos** OE1. Comparar el IoU de agua de TerraMind v1-B, Prithvi-EO-2.0 300M y U-Net en Sen1Floods11 y en los eventos peruanos de 2023 y 2017, con tres esquemas de entrenamiento, para seleccionar el modelo del sistema. OE2. Determinar en qué medida la adaptación de dominio no supervisada y la calibración de la incertidumbre mejoran la confiabilidad de los mapas en el Perú, e identificar las condiciones en las que se concentran los errores. OE3. Implementar el sistema como una aplicación web y evaluar si cumple los requisitos funcionales y el tiempo de procesamiento por escena Sentinel-2.	**Hipótesis específicas** HE1. En Sen1Floods11 no se detecta una diferencia significativa de IoU de agua entre los modelos fundacionales y la U-Net (IC 95 %). En el Perú, la caída de IoU de los modelos fundacionales es menor que la de la U-Net. HE2. Los errores en el Perú se concentran en pocas condiciones: bordes de nubes, vegetación inundada y terreno desértico o costero. La adaptación aumenta el IoU de agua respecto del modelo sin adaptar (IC 95 % mayor que cero), sin llegar al modelo entrenado en el Perú. Sin calibrar, los modelos son sobreconfiados; el escalado de temperatura y los ensambles reducen el ECE, y la incertidumbre permite detectar errores (AUROC mayor que 0.5). HE3. El sistema cumple el 100 % de los requisitos funcionales RF1 a RF7 y procesa una escena Sentinel-2 completa en 15 minutos o menos, incluida la descarga.	**Variable dependiente (Y)** Calidad del mapeo de inundaciones. **Dimensiones:** Y1. Exactitud de la segmentación. Y2. Generalización al Perú. Y3. Calibración. Y4. Detección de errores. Y5. Desempeño del sistema. **Variables intervinientes** Evento (2023 o 2017), calidad de las etiquetas y cobertura de nubes.	**Población:** imágenes Sentinel-2 L1C de eventos de inundación. **Muestra (no probabilística):** Sen1Floods11, particiones oficiales (252 de entrenamiento, 89 de validación y 90 de prueba); Perú 2023, 1 291 recortes por bloques espaciales (753, 174 y 172, más 192 de separación sin uso); Perú 2017, 204 recortes solo de prueba (101 en la evaluación principal); escenas completas para el sistema. **Técnicas e instrumentos de recolección de datos:** descarga desde Copernicus Data Space; etiquetas generadas por reglas a partir de los mapas de UNOSAT (2023) y Copernicus EMS (2017), sin etiquetado manual; programas del repositorio versionados con *git*; registros de pruebas y de tiempos del sistema. **Técnicas e instrumentos de análisis y procesamiento:** IoU de agua, precisión, *recall* y mIoU; ECE; AUROC; diferencias pareadas con IC 95 % por remuestreo *bootstrap* (2 000 réplicas); media y desviación estándar de tres semillas; lista de verificación de RF1 a RF7; tiempo por escena.

Autores: Gerson Andre Garrido Mansilla, Renzo Elvis Cerron Tome.
Elaboración: propia, a partir de los Capítulos I y III de la tesis.

Tabla B. Matriz de trazabilidad: de cada hipótesis específica a su indicador, instrumento, evidencia y estado

Afirm.	PE / OE / HE	Dimensión	Indicador	Criterio de contrastación	Instrumento	Evidencia	Estado
1a	PE1 / OE1 / HE1	Y1. Exactitud de la segmentación	Diferencia pareada de IoU de agua entre la U-Net y cada modelo fundacional, prueba de Sen1Floods11	El IC 95 % incluye el cero	`scripts/evaluate_frozen.py`, `scripts/bootstrap_frozen.py`	`outputs/phaseD/test/bootstrap_diffs.csv`; Cap. III, §3.3	Coherente: no se detectó una diferencia. U-Net − Prithvi: +0.013 [−0.022; 0.062]; U-Net − TerraMind: +0.015 [−0.018; 0.051].
1b	PE1 / OE1 / HE1	Y2. Generalización al Perú	Diferencia de caídas D = caída de la U-Net − caída del modelo fundacional (Sen1Floods11 → prueba Perú 2023)	IC 95 % de D por encima de cero	`scripts/bootstrap_drop_diff.py` (análisis *post hoc*)	`outputs/phaseD/test/bootstrap_drop_diff.csv`	Se confirma parcialmente. Prithvi: D = 0.177 [0.102; 0.253]. TerraMind: D = 0.064 [0.001; 0.120], con semillas solapadas con la U-Net.
2a	PE2 / OE2 / HE2	Y1. Exactitud de la segmentación	Razón de concentración por estrato (proporción de errores / proporción de píxeles), validación peruana	Razón ≥ 2 en los estratos nombrados (criterio fijado después de ver los resultados)	`scripts/error_shares_dev.py`	`outputs/phaseD/analysis/error_shares.csv`	Respaldo exploratorio parcial: solo la vegetación inundada cumple el criterio (U-Net y Prithvi); la mayor concentración está en el borde del agua.
2b	PE2 / OE2 / HE2	Y2. Generalización al Perú	Diferencia pareada de IoU de agua: adaptado − origen y adaptado − entrenado en el Perú	IC 95 % de la primera > 0 y del modelo adaptado por debajo del entrenado en el Perú	`scripts/evaluate_frozen.py`, `scripts/bootstrap_frozen.py`	`outputs/phaseD/test/bootstrap_diffs.csv`	Se confirma en 2023: U-Net +0.222 [0.132; 0.309]; TerraMind +0.082 [0.016; 0.156]. Se refuta frente a la referencia de 2017: U-Net −0.063; TerraMind −0.103. Prithvi sin configuración adaptada.
2c	PE2 / OE2 / HE2	Y3. Calibración; Y4. Detección de errores	Temperatura ajustada T; ECE (%); AUROC de la incertidumbre	$T > 1$; ECE menor con temperatura y con ensamble; AUROC > 0.5	`scripts/phaseD_analysis.py`, `scripts/calibration_frozen.py`	`outputs/phaseD/analysis/temperatures.json`; `outputs/phaseD/test/calibration.md`	Se confirma en las configuraciones congeladas: AUROC de 0.598 a 0.783. Excepción fuera de ellas: Prithvi entrenado en el Perú (0.439).
3	PE3 / OE3 / HE3	Y5. Desempeño del sistema	Requisitos funcionales cumplidos (%); tiempo por escena (min), 6 teselas × 3 repeticiones	100 % de RF1 a RF7; mediana $\leq$ 15 min en cada tesela	`scripts/system_rf*_check.py`, `scripts/system_timing.py`; `docs/system_evaluation_protocol.md`	`outputs/system_eval/`	Pendiente de la medición formal. Verificaciones preliminares superadas: RF1, RF3 y RF5.

Nota. Los intervalos son IC 95 % por remuestreo *bootstrap* pareado de recortes (2 000 réplicas) sobre el IoU medio de tres semillas. Las cifras de 2017 corresponden a los 101 recortes que no se superponen con el entrenamiento de 2023. Las etiquetas de 2017 conservan solo los píxeles en que EMS y el índice MNDWI concuerdan, por lo que miden sobre todo la exhaustividad. El detalle de cada veredicto está en el Capítulo III, §3.3.
Autores: Gerson Andre Garrido Mansilla, Renzo Elvis Cerron Tome.
Elaboración: propia.